

Ekler (Appendix)

Binom ve p İcin Maksimum Olurluk Tahmini [1]

$$L(p; x) = \prod_{i=1}^n f(x_i; p) = \prod_{i=1}^n \binom{n}{x} p^x (1-p)^{1-x}$$

Log alalım

$$\log L(p; x) = \sum_{i=1}^n \log \binom{n}{x} + x \log p + (1-x) \log(1-p)$$

p'ye göre türevi alalım, bu sırada kombinasyon ifadesi $\binom{n}{x}$ içinde p olmadığı için o yok olacaktır,

$$\frac{\partial \log L(p)}{\partial p} = \frac{x}{p} - \frac{n-x}{1-p}$$

Maksimum değeri bulmak için sifıra eşitleyelim ve p için çözelim,

$$0 = \frac{x}{p} - \frac{n-x}{1-p}$$

$$\frac{x}{p} = \frac{n-x}{1-p}$$

$$p(n-x) = x(1-p)$$

$$pn - px = x - px$$

$$pn = x$$

$$p = \frac{x}{n}$$

Yani p için maksimum olurluk tahmini x/n .

Bernoulli dağılımı Binom dağılımına çok benzer, sadece onun baş kısmında kombinasyon ifadesi yoktur. Fakat o ifade p'ye göre türevde nasıl olsa yokolacağına göre Bernoulli dağılımı için de tahmin edici aynıdır.

Bayes Usulu Güven Aralığı (Confidence Intervals)

Bayes ile bu hesabi yapmak için bir dağılımı baz almak lazım. Eğer sonuç olarak bir tekil sayı değil, bir dağılım elde edersek bu dağılım üzerinde güvenlik hesaplarını yaparız. Mesela sonuç, sonsal dağılım (posterior) bir Gaussian dağılım ise, bu dağılımın yüzde 95 ağırlığının nerede olduğu, ve nasıl hesaplandığı bellidir.

Bayes Teorisi

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Veri analizi bağlamında diyelim ki deneyler yaparak tahmini olarak hesaplamak (estimate) istediğimiz bir parametre var, bu bir protonun kutlesi ya da bir ameliyat sonrası hayatta kalma oranı olabilir. Bu durumlarda iki ayrı "olaydan" bahsetmemiz gerekir, B olayı spesifik bazı ölçümlerin elde edilmesi "olaydır", mesela ölçüm üç sayıdan oluşuyorsa, biz bir ölçümde spesifik olarak {0.2, 4, 5.4} değerlerini elde etmişiz. İkinci olay bilmediğimiz parametrenin belli bir değere sahip olması olacak. O zaman Bayes Teorisinin şu şekilde tekrar yazabiliriz,

$$P(\text{parametre}|\text{veri}) \propto P(\text{data}|\text{parametre})P(\text{parametre})$$

\propto isareti orantili olmak (proportional to) anlamına geliyor. Boleni attık çünkü o bir sabit (tamamen veriye bağlı, tahmini hesaplamak istediğimiz parametreye bağlı değil). Tabii bu durumda sol ve sağ taraf birbirine eşit olmaz, o yüzden eşitlik yerine orantili olmak isaretini kullandık. Bu çerçevede "belli bir numerik sabit çerçevesinde birbirine eşit (equal within a numeric constant)" gibi cümleler de görülebilir.

Örnek

Diyelim ki bir bozuk para ile 10 kere yazı-tura attık, ve sonuç altta

T H H H H T T H H H

Bu veriye bakarak paranın hileli olup olmadığını anlamaya çalışacağız. Bayes ifadesini bu veriye göre yazalım,

$$P(p|\{T H H H H T T H H H\}) \propto P(\{T H H H H T T H H H|p\})P(p)$$


$P(p)$ ifadesi ne anlama gelir? Aslında bu ifadeyi $P([Dağılım] = p)$ olarak görmek daha iyi, artık p parametresini bir dağılımdan gelen bir tekil değer olarak gördüğümüze göre, o dağılımın belli bir p 'ye eşit olduğu zamanı modelliyoruz burada. Her halukarda $P(p)$ dağılımını, yani onsel (prior) olasılığı bilmiyoruz, hesaptan önce her değer mümkün olduğunu biliyoruz, o zaman bu onsel dağılımı düz (flat) olarak alırız, yani $P(p) = 1$.

$P(\{T H H H H T T H H H|p\})$ ifadesi göz korkutucu olabilir, ama buradaki her oğenin bağımsız özdeşce dağılmış (independent identically distributed) olduğunu görürsek,

ama bu ifadeyi ayrı ayrı $P(\{T|p\})$ ve $P(\{H|p\})$ carpımları olarak görebiliriz. $P(\{T|p\}) = p$ ve $P(\{H|p\}) = 1 - p$ olduğunu biliyoruz. O zaman

$$P(p|\{7 \text{ Tura}, 3 \text{ Yazı}\}) \propto p^7(1-p)^3$$

Grafiklersek,



Boylece p için bir sonsal dağılım elde ettik. Artık bu dağılımın yüzde 95 ağırlığının nerede olduğunu rahatca görebiliriz / hesaplayabiliriz. Dağılımın tepe noktasının $p = 0.7$ civarında olduğu görülüyor. Bir dağılımla daha fazlasını yapmak mümkün, mesela bu fonksiyonu p 'ye bağlı başka bir fonksiyona karşı entegre etmek mümkün, mesela beklentiği bu şekilde hesaplayabiliriz.

Onsel dağılımın her noktaya eşit ağırlık veren bir örnek (uniform) seçilmiş olması, yani problemi çözmeye sıfır bilgidan başlamış olmamız, yöntemin bir zayıflığı olarak görülmemeli. Yöntemin kuvveti elimizdeki bilgiyle başlayıp onu net bir şekilde veri ve olurluk üzerinden sonsal tek dağılıma götürebilmesi. Başlangıç ve sonuç arasındaki bağlantı gayet net. Fazlası da var; ilgilendığımız alanı (domain) öğrendikçe, basta hiç bilmediğimiz onsel dağılımı daha net, bilgili bir şekilde seçebiliriz ve bu sonsal dağılımı da daha olması gereken modele daha yaklaştırabilir.

Cok Boyutlu Gaussian'ı Parcalamak (Partitioning)

Diyelim ki Normal bir vektör X 'i $X = (X_1, X_2)$ olarak parçaladık. Bunu Gaussian'a etkileri ne olur? Aynı şekilde $\mu = (\mu_1, \mu_2)$ olarak parcalayabiliriz. Σ ise

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

olarak parçalanabilir. a, b 'nin parçalarının boyutları p, q olsun, $n = p + q$.

Simdi birlesik Gaussian'ı

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{(p+q)/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

Birlesik yogunlugu parcalar uzereinden belirtirsek, bu yogunlugu X_2 icin bilezen yogunluga ve X_1 icin bir kosullu yogunluga ayirabiliriz. Yani

$$f(x_1, x_2) = f(x_1|x_2)f(x_2)$$

tanimindaki parcalari elde etmeye calisacagiz. Ama bundan once boluntulenmis matrislere yakindan bakalim.

Bir boluntulenmis (partitioned) matrisin tersini almak icin, o matrisin parcalarinin tersini almak dogru degildir, yani

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} \neq \begin{bmatrix} E^{-1} & F^{-1} \\ G^{-1} & H^{-1} \end{bmatrix}$$

Tersini alma islemi icin bazi numaralar lazim. Ana numara boluntulenmis matrisi kosegen bir matris haline getirmek, cunku kosegen matrislerin tersi, kosegendeki elemanlari tersidir, yani ters alma operasyonu bu tur matrislerin “icine isler”, o yuzden bir sekilde bir kosegen matris elde etmeye ugrasacagiz. Bunun icin boluntulenmis matrisimizi sagdan ve soldan bazi matrislerle carpacagiz. Ayrica sunu da bilelim,

$$XYZ = W$$

durumunda Y 'nin tersini almak istersek, sag ve soldaki X, Z matrislerinin tersini almak gerekmez, niye?

$$X^{-1}XYZ = X^{-1}W$$

$$YZZ^{-1} = X^{-1}WZ^{-1}$$

$$Y = X^{-1}WZ^{-1}$$

Simdi iki tarafin da tersini alalim,

$$Y^{-1} = ZW^{-1}X$$

Tamam, baslatalim.

$$M = \begin{bmatrix} E & F \\ G & H \end{bmatrix}$$

matrisini kosegen yapacagiz. Eger sadece alt sol koseyi sifirlayasaydik, bunu yapacak ozel bir matrisle soldan carpardik,

$$\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} = \begin{bmatrix} E & F \\ 0 & H \end{bmatrix}$$

Sadece ust sag koseyi sifirlamak isteseydik, sagdan carpardik

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix} \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} = \begin{bmatrix} E & 0 \\ G & H \end{bmatrix}$$

Hepsini biraraya koyalım,

$$\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} = \begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}$$

Bu carpimin dogrulugu carpim elle yapilarak kontrol edilebilir.

Ustte gordugumuz gibi

$$XYZ = W$$

ifadesindeki Y'nin tersi

$$Y^{-1} = ZW^{-1}X$$

ile olur.

$$\underbrace{\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}}_X \underbrace{\begin{bmatrix} E & F \\ G & H \end{bmatrix}}_Y \underbrace{\begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix}}_Z = \underbrace{\begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}}_W$$

O zaman

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} = \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} \begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}^{-1} \begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}$$

Daha kısa olmasi esitligin sag tarafinda, ortadaki matris icin $E - FH^{-1}G$ yerine M/H kullanalim (bu arada M/H lineer cebirde “M’in H’e gore Schur tamamlayicisi (complement)” olarak bilinir),

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} = \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} \begin{bmatrix} (M/H)^{-1} & 0 \\ 0 & H^{-1} \end{bmatrix} \begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}$$

Esitligin sag tarafindaki carpimi gerceklestirirsek,

$$= \begin{bmatrix} (M/H)^{-1} & -(M/H)^{-1}FH^{-1} \\ -H^{-1}G(M/H)^{-1} & H^{-1} + H^{-1}G(M/H)^{-1}FH^{-1} \end{bmatrix}$$

Bu final ifade boluntulenmis bir matrisin tersini o matrisin icindeki parcalar uzerinden temsil eden bir ifadedir.

Icinde bir kosesi sifir olan boluntulenmis matrislerde determinantlar soyle isler,

$$\det \left(\begin{bmatrix} E & 0 \\ G & H \end{bmatrix} \right) = \det \left(\begin{bmatrix} E & F \\ 0 & H \end{bmatrix} \right) = \det(E) \det(H)$$

Ayrica

$$\det(AB) = \det(A) \det(B)$$

O zaman (2)'nin determinantini alirsak, det yerine $\|$ kullandik,

$$|M| = |M/H||H|$$

Bu ifade gayet dogal duruyor (bir raslanti herhalde, ya da Schur tamamlayicisi isareti ozellikle boyle secilmis),

Boluntulenmis bir matrisin devrigini almak için her blogunun ayrı ayrı devrigi alınır, ve tüm blokların yani boluntulenmis tamamının bir daha devrigi alınır, yani

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^T = \begin{bmatrix} A^T & C^T \\ B^T & D^T \end{bmatrix}$$

Simdi çok degiskenli Normal için bileşen ve koşullu yoğunluk hesaplarına gelelim. Gaussian formülünün exp kısmını alırsak,

$$\exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

(3)'teki acilimi kullanırsak, ve $E = \Sigma_{11}$, $F = \Sigma_{12}$, .. olacak şekilde,

$$\exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} I & 0 \\ -\Sigma_{22}^{-1}\Sigma_{21} & I \end{bmatrix} \begin{bmatrix} (\Sigma/\Sigma_{22}) & 0 \\ 0 & \Sigma_{22}^{-1} \end{bmatrix} \begin{bmatrix} I & -\Sigma_{12}\Sigma_{22}^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

Acilimi tamamen yaparsak,

$$= \exp \left\{ -\frac{1}{2} (x_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2))^T (\Sigma/\Sigma_{22})^{-1} (x_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)) \right\} \cdot \exp \left\{ \frac{1}{2} (x_2 - \mu_2)^T \Sigma_{22}^{-1} (x_2 - \mu_2) \right\}$$

Not: $\Sigma_{12}^T = \Sigma_{21}$. Üstte birinci exp içinde sol bölümde devrigin içindeki ifadelerden, mesela x_1^T, μ_1^T 'den ve Σ_{21} 'li ifadeden devrik işlemini çekip, büyük paranteze alınıncaya bu değişim oldu.

Simdi mesela 1. exp'ye dikkat edersek, ortada $(\Sigma/\Sigma_{22})^{-1}$ var, ve bu ifadenin solunda ve sağında birbirinin devrigi olan aynı terimler duruyor. Ifadenin tamamı bir Normal dağılım. Aynı şey 2. exp için geçerli.

İsin exp tarafını hallettik. Simdi exp öncesindeki kesiri (4) kullanarak parçalayalım,

$$\frac{1}{(2\pi)^{(p+q)/2} \det(\Sigma)^{1/2}} = \frac{1}{(2\pi)^{(p+q)/2} \left(\det(\Sigma/\Sigma_{22}) \det(\Sigma_{22}) \right)^{1/2}} \\ = \left(\frac{1}{(2\pi)^{p/2} \det(\Sigma/\Sigma_{22})^{1/2}} \right) \left(\frac{1}{(2\pi)^{q/2} \det(\Sigma_{22})^{1/2}} \right)$$

Bu parçaların her birini ayrı bir exp onunde kullanabiliriz, ve ikinci exp ifadesinin

$$\frac{1}{(2\pi)^{q/2} \det(\Sigma_{22})^{1/2}} \exp \left\{ \frac{1}{2} (x_2 - \mu_2)^T \Sigma_{22}^{-1} (x_2 - \mu_2) \right\}$$

olduğunu görüyoruz. Bu ifade $f(x_2)$ bileşen yoğunludur! O zaman geri kalanlar, yani diğer kesir ve birinci exp hep beraber $f(x_1|x_2)$ yoğunluğu olmalıdır. Yani,

$$\frac{1}{(2\pi)^{p/2} \det(\Sigma/\Sigma_{22})^{1/2}} \cdot$$

$$\exp \left\{ -\frac{1}{2}(\mathbf{x}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2))^T (\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{22})^{-1}(\mathbf{x}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2)) \right\}$$

Buradan genel bir kural cikartabiliriz,

1) X_2 'nin bilesen yogunlugu $X_2 \sim N(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$

2) $X_2 = \mathbf{x}_2$ olmak uzere X_1 'in kosullu dagilimi

$$X_1|X_2 = \mathbf{x}_2 \sim N\left(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{22}\right)$$

$\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{22}$ nedir? Hatirlarsak, $M/H = E - FH^{-1}G$, ve $E = \boldsymbol{\Sigma}_{11}, F = \boldsymbol{\Sigma}_{12}, ..$ o zaman

$$\boldsymbol{\Sigma}/\boldsymbol{\Sigma}_{22} = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$$

Yani

$$X_1|X_2 = \mathbf{x}_2 \sim N\left(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}\right)$$

Moment

Olasılık matematiğinde "moment üreten işlevler" olarak adlandırılan, başlangıçta pek yararlı gibi gözükmesede bir takım matematiksel özellikleri olduğu için, ispatlarda oldukça işe yarayan bir kavram vardır.

Her rasgele değişkenin bir dağılımı olduğunu biliyoruz. Her rasgele değişkenin de ayrıca bir moment üreten fonksiyonu da vardır. Ayrıca, moment üreten fonksiyon ile rasgele değişken arasında bire-bir olarak bir ilişki mevcuttur. "Bu neye yarar?" diye sorulabilir; Cevap olarak, mesela cebirsel olarak türete türete bir moment'e geldiğimiz düşünelim, ve tekrar başka bir taraftan, başka bir formülden gene türete türete tekrar aynı moment işlevine geliyorsak, bu demektir ki, iki taraftan gelen rasgele değişkenler (ve tekabül eden dağılımları) birbirine eşittir. Bazı şartlarda moment üreten işlevler ile cebir yapmak, dağılım fonksiyonlarından daha rahat olmaktadır.

Her rasgele değişken için, moment üreten işlev şöyle bulunur.

X rasgele degiskenin moment ureten operasyonu

$$M(t) = E(e^{tX}) \text{ olarak gosterilir}$$

Ayriksal operasyonlar icin

$$M(t) = \sum_x e^{tx} p(x)$$

Surekli islevler icin

$$M(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

Kuram

Gelelim yazımızın esas konusu olan kuramımıza.

Eğer X_1, X_2, \dots, X_n bağımsız rasgele değişken ise, ve her değişkenin $M_i(t)$ $i = 1, 2, 3, \dots, n$ olarak, öz olarak aynı olan birer moment üreten işlevi var ise, o zaman,

$$Y = \sum_{i=1}^n a_i X_i$$

acilimi

$$M_y(t) = \prod_{i=1}^n M(a_i t)$$

olacaktır.

Ispat

$$M_y(t) = E(e^{tY}) = E(e^{t(a_1 X_1 + a_2 X_2 + \dots + a_n X_n)})$$

$$= E[\exp(t a_1 X_1 + t a_2 X_2 + \dots + t a_n X_n)]$$

$$= E[\exp(t a_1 X_1) + \exp(t a_2 X_2) + \dots + \exp(t a_n X_n)]$$

$$= E[\exp(t a_1 X_1)] + E[\exp(t a_2 X_2)] + \dots + E[\exp(t a_n X_n)]$$

Daha önce belirttiğimiz gibi

$$M_i(t) = E[\exp(t X_i)]$$

olduğuna göre ve t yerine $t a_i$ koyulduğunu düşünelim


$$M_y(t) = \prod_{i=1}^n M_y(a_i t)$$

olacaktır.

Bunu $M_y(t) = (M_i(a_i t))^n$ şeklinde de gösterebiliriz.

z-Tablosu

Nasil okunur? Z-degeri -0.8994 icin z kolonundan asagi inilir, ve -0.8 bulunur, x.x9xx yani 9 icin .09 kolonuna gidilir ve bu kesismedeki deger okunur, .1867, yuvarlanarak .19 da kabul edilebilir.



z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
-3.4	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0002
-3.3	.0005	.0005	.0005	.0004	.0004	.0004	.0004	.0004	.0004	.0003
-3.2	.0007	.0007	.0006	.0006	.0006	.0006	.0006	.0005	.0005	.0005
-3.1	.0010	.0009	.0009	.0009	.0008	.0008	.0008	.0008	.0007	.0007
-3.0	.0013	.0013	.0013	.0012	.0012	.0011	.0011	.0011	.0010	.0010
-2.9	.0019	.0018	.0018	.0017	.0016	.0016	.0015	.0015	.0014	.0014
-2.8	.0026	.0025	.0024	.0023	.0023	.0022	.0021	.0021	.0020	.0019
-2.7	.0035	.0034	.0033	.0032	.0031	.0030	.0029	.0028	.0027	.0026
-2.6	.0047	.0045	.0044	.0043	.0041	.0040	.0039	.0038	.0037	.0036
-2.5	.0062	.0060	.0059	.0057	.0055	.0054	.0052	.0051	.0049	.0048
-2.4	.0082	.0080	.0078	.0075	.0073	.0071	.0069	.0068	.0066	.0064
-2.3	.0107	.0104	.0102	.0099	.0096	.0094	.0091	.0089	.0087	.0084
-2.2	.0139	.0136	.0132	.0129	.0125	.0122	.0119	.0116	.0113	.0110
-2.1	.0179	.0174	.0170	.0166	.0162	.0158	.0154	.0150	.0146	.0143
-2.0	.0228	.0222	.0217	.0212	.0207	.0202	.0197	.0192	.0188	.0183
-1.9	.0287	.0281	.0274	.0268	.0262	.0256	.0250	.0244	.0239	.0233
-1.8	.0359	.0351	.0344	.0336	.0329	.0322	.0314	.0307	.0301	.0294
-1.7	.0446	.0436	.0427	.0418	.0409	.0401	.0392	.0384	.0375	.0367
-1.6	.0548	.0537	.0526	.0516	.0505	.0495	.0485	.0475	.0465	.0455
-1.5	.0668	.0655	.0643	.0630	.0618	.0606	.0594	.0582	.0571	.0559

-1.4 .0808 .0793 .0778 .0764 .0749 .0735 .0721 .0708 .0694 .0681
-1.3 .0968 .0951 .0934 .0918 .0901 .0885 .0869 .0853 .0838 .0823
-1.2 .1151 .1131 .1112 .1093 .1075 .1056 .1038 .1020 .1003 .0985
-1.1 .1357 .1335 .1314 .1292 .1271 .1251 .1230 .1210 .1190 .1170
-1.0 .1587 .1562 .1539 .1515 .1492 .1469 .1446 .1423 .1401 .1379
-0.9 .1841 .1814 .1788 .1762 .1736 .1711 .1685 .1660 .1635 .1611
-0.8 .2119 .2090 .2061 .2033 .2005 .1977 .1949 .1922 .1894 .1867
-0.7 .2420 .2389 .2358 .2327 .2296 .2266 .2236 .2206 .2177 .2148
-0.6 .2743 .2709 .2676 .2643 .2611 .2578 .2546 .2514 .2483 .2451
-0.5 .3085 .3050 .3015 .2981 .2946 .2912 .2877 .2843 .2810 .2776
-0.4 .3446 .3409 .3372 .3336 .3300 .3264 .3228 .3192 .3156 .3121
-0.3 .3821 .3783 .3745 .3707 .3669 .3632 .3594 .3557 .3520 .3483
-0.2 .4207 .4168 .4129 .4090 .4052 .4013 .3974 .3936 .3897 .3859
-0.1 .4602 .4562 .4522 .4483 .4443 .4404 .4364 .4325 .4286 .4247
0.0 .5000 .4960 .4920 .4880 .4840 .4801 .4761 .4721 .4681 .4641

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0.0	.5000	.5040	.5080	.5120	.5160	.5199	.5239	.5279	.5319	.5359
0.1	.5398	.5438	.5478	.5517	.5557	.5596	.5636	.5675	.5714	.5753
0.2	.5793	.5832	.5871	.5910	.5948	.5987	.6026	.6064	.6103	.6141
0.3	.6179	.6217	.6255	.6293	.6331	.6368	.6406	.6443	.6480	.6517
0.4	.6554	.6591	.6628	.6664	.6700	.6736	.6772	.6808	.6844	.6879
0.5	.6915	.6950	.6985	.7019	.7054	.7088	.7123	.7157	.7190	.7224
0.6	.7257	.7291	.7324	.7357	.7389	.7422	.7454	.7486	.7517	.7549
0.7	.7580	.7611	.7642	.7673	.7704	.7734	.7764	.7794	.7823	.7852
0.8	.7881	.7910	.7939	.7967	.7995	.8023	.8051	.8078	.8106	.8133
0.9	.8159	.8186	.8212	.8238	.8264	.8289	.8315	.8340	.8365	.8389
1.0	.8413	.8438	.8461	.8485	.8508	.8531	.8554	.8577	.8599	.8621
1.1	.8643	.8665	.8686	.8708	.8729	.8749	.8770	.8790	.8810	.8830
1.2	.8849	.8869	.8888	.8907	.8925	.8944	.8962	.8980	.8997	.9015
1.3	.9032	.9049	.9066	.9082	.9099	.9115	.9131	.9147	.9162	.9177
1.4	.9192	.9207	.9222	.9236	.9251	.9265	.9279	.9292	.9306	.9319
1.5	.9332	.9345	.9357	.9370	.9382	.9394	.9406	.9418	.9429	.9441
1.6	.9452	.9463	.9474	.9484	.9495	.9505	.9515	.9525	.9535	.9545
1.7	.9554	.9564	.9573	.9582	.9591	.9599	.9608	.9616	.9625	.9633
1.8	.9641	.9649	.9656	.9664	.9671	.9678	.9686	.9693	.9699	.9706
1.9	.9713	.9719	.9726	.9732	.9738	.9744	.9750	.9756	.9761	.9767
2.0	.9772	.9778	.9783	.9788	.9793	.9798	.9803	.9808	.9812	.9817
2.1	.9821	.9826	.9830	.9834	.9838	.9842	.9846	.9850	.9854	.9857
2.2	.9861	.9864	.9868	.9871	.9875	.9878	.9881	.9884	.9887	.9890
2.3	.9893	.9896	.9898	.9901	.9904	.9906	.9909	.9911	.9913	.9916
2.4	.9918	.9920	.9922	.9925	.9927	.9929	.9931	.9932	.9934	.9936
2.5	.9938	.9940	.9941	.9943	.9945	.9946	.9948	.9949	.9951	.9952
2.6	.9953	.9955	.9956	.9957	.9959	.9960	.9961	.9962	.9963	.9964
2.7	.9965	.9966	.9967	.9968	.9969	.9970	.9971	.9972	.9973	.9974
2.8	.9974	.9975	.9976	.9977	.9977	.9978	.9979	.9979	.9980	.9981

2.9 .9981 .9982 .9982 .9983 .9984 .9984 .9985 .9985 .9986 .9986

3.0 .9987 .9987 .9987 .9988 .9988 .9989 .9989 .9989 .9990 .9990

3.1 .9990 .9991 .9991 .9991 .9992 .9992 .9992 .9992 .9993 .9993

3.2 .9993 .9993 .9994 .9994 .9994 .9994 .9994 .9995 .9995 .9995

3.3 .9995 .9995 .9995 .9996 .9996 .9996 .9996 .9996 .9996 .9997

3.4 .9997 .9997 .9997 .9997 .9997 .9997 .9997 .9997 .9997 .9998

Kaynaklar

[1] http://pages.uoregon.edu/aarong/teaching/G4075_Outline/node13.html