

Kovaryans ve Korelasyon

Harvard Joe Blitzstein dersinden alınmıştır

Bugün “kovaryans gunu”, bu teknigi kullanarak nihayet bir toplamın varyansını bulabileceğiz, varyans lineer değildir (kiyasla beklenti -expectation- lineerdir). Bu lineer olmama durumu bizi korkutmayacak tabii, sadece yanlış bir şekilde lineerlik uygulamak yerine probleme farklı bir şekilde yaklaşmayı öğreneceğiz.

Diğer bir açıdan, hatta bu ana kullanımlardan biri, kovaryans iki rasgele değişkeni beraber / aynı anda analiz etmemize yarayacak. İki varyans olacak, ve onların alakasına bakıyor olacağız, bu sebeple bu analize kovaryans deniyor zaten.

Tanım

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y))) \quad (1)$$

Burada X, Y aynı uzayda tanımlanmış herhangi iki rasgele değişken. Üstteki diyor ki rasgele değişken X, Y 'in kovaryansı X 'ten ortalaması çıkarılmış, Y 'ten ortalaması çıkarılmış halinin çarpılması ve tüm bu çarpımların ortalamasının alınmasıdır.

Tanım böyle. Şimdi bu tanıma biraz bakıp onun hakkında sezgi / anlayış geliştirmeye uğralım. Tanım niye bu şekilde yapılmış, başka bir şekilde değil?

İlk önce esitliğin sağ tarafındaki bir çarpımdır, yani “bir şey carpi bir başka şey”. Bu “şeylerden” biri X ile diğeri Y ile alakalı, onları carparak ve çarpımın bir özelliğinden faydalanarak sunu elde ettik; artı carpi artı yine artı degerdir, eksi carpi artı eksidir, eksi carpi eksi artıdır. Bu şekilde mesela “aynı anda artı” olmak gibi kuvvetli bir bağlantı çarpımın artı olması ile yakalanabilecektir. Aynı durum eksi,eksi de için geçerli, bu sefer her iki rasgele değişken aynı şekilde negatiftir. Eksi çarpım sonucu ise sıfırdan az bir degerdir, “kotu korelasyon” olarak alınabilir ve hakikaten de eksi artı çarpımının isareti olduğu için iki değişkenin ters yönlere olduğunu gösterir. Demek ki bu araç / numara hakikaten faydalı.

Unutmayalım, üstteki çarpımlardan birisinin büyüklüğü X 'in ortalamasına bağlı olan bir diğer, Y aynı şekilde. Şimdi X, Y 'den bir örneklem (sample) aldığımızı düşünelim. Veri setinin her veri noktası bağımsız ve aynı şekilde dağılmış (i.i.d) durumda. Yani X, Y değişkenlerine “gelen” x_i, y_i ikilileri her i için diğerlerinden bağımsız; fakat her ikilinin arasında bir bağlantı var, yani demek ki bu rasgele değişkenlerin baz aldığı dağılımların bir alakası var, ya da bu iki değişkenin bir birleşik dağılımı (joint distribution) var.

Not: Eğer X, Y bağımsız olsaydı, o zaman

$$\text{Cov}(X, Y) = E((X - E(X))E(Y - E(Y)))$$

olarak yazılabilirdi, yani iki beklentinin ayrı ayrı çarpılabildiği durum... Ama biz bu derste bağımsızlığın olmadığı durumla ilgileniyoruz..

Korelasyon kelimesinden bahsedelim hemen, bu kelime gunluk konusmada cok kullaniliyor, ama bu ders baglaminda korelasyon kelimesinin matematiksel bir anlami olacak, onu birazdan, kovaryans uzerinden tanimlayacagiz.

Bazi ilginc noktalar:

Ozellik 1

varyansi nasil tanimlamistik?

$$\text{Var}(X) = E((X - E(X))^2)$$

Bu denklem aslinda

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y)))$$

denkleminde Y yerine X kullandigimizda elde ettigimiz seydir, yani

$$\text{Cov}(X, X) = E((X - E(X))(X - E(X)))$$

$$\text{Cov}(X, X) = E((X - E(X))^2)$$

$$= \text{Var}(X)$$

Yani varyans, bir degiskenin “kendisi ile kovaryansidir”. Ilginc degil mi?

Ozellik 2

$$\text{Cov}(X, Y) = \text{Cov}(Y, X)$$

Ispati kolay herhalde, (1) formuluunu uygulamak yeterli.

Teori

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y)$$

Ispat

Bu ispat cok kolay, esitligin sol tarafindaki carpimi parantezler uzerinden acarsak, ve beklenti lineer bir operator oldugu icin toplam terimleri uzerinde ayri ayri uygulanabilir,

$$E(XY) - E(X)E(Y) - E(X)E(Y) + E(X)E(Y)$$

$$= E(XY) - E(X)E(Y)$$

Carpimi uygularken mesela $E(-X \cdot E(Y))$ gibi bir durum ortaya çıktı, burada $E(Y)$ 'nin bir sabit olduğunu unutmayalım, çünkü beklenti rasgele degiskene uygulanınca tek bir sayı ortaya çıkartır, ve şu $E(Y)$ üzerinde bir beklenti daha uygulanınca bu “icerideki” beklenti sabitmiş gibi dışarı çıkartılabilir, yani $-E(X)E(Y)$.

Devam edelim, $E(XY) - E(X)E(Y)$ ifadesini gösterdik, çünkü çoğu zaman bu ifade hesap açısından (1)'den daha uygundur. Ama (1) ifadesi anlatım / sezgisel kavrayış açısından daha uygun, çünkü bu ifade X 'in ve Y 'nin kendi ortalamalarına izafi olarak belirtilmiştir, ve akılda canlandırılması daha rahat olabilir. Fakat matematiksel olarak bu iki ifade de aynidir.

İki özellik bulduk bile. Bir özellik daha,

Ozellik 3

$$\text{Cov}(X, c) = 0$$

Bu nereden geldi? (1)'e bakalım, Y yerine c koymuş olduk, yani bir sabit. Bu durumda (1)'in $(Y - E(Y))$ kısmı $c - E(c) = c - c = 0$ olur [aslında bayagi absürt bir durum], ve bu durumda (1) tamamen sifira dönüşür, sonuç sıfır.

Ozellik 4

$$\text{Cov}(cX, Y) = c \cdot \text{Cov}(X, Y)$$

İspat için alttaki formülde

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

X yerine cX koymak yeterli, c her iki terimde de dışarı çıkacaktır, ve grubun dışına alınca bu özelliği elde ederiz.

Ozellik 5

$$\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$$

İspat için bir üstteki özellikte yaptığımızın benzerini yaparız.

En son iki özellik oldukça faydalıdır bu arada, onlara ikili-lineerlik (bilinearity) ismi veriliyor. İsim biraz renkli / başarılı bir isim, söylemek istediği şu aslında, bu son iki özellikte sanki bir kordinati sabit tutup diğeri ile işlem yapmış gibi oluyoruz, yani bir kordinat sabit olunca diğeri “lineermiş gibi” oluyor; Mesela c 'nin dışarı çıktığı durumda olduğu gibi, bu özellikte Y 'ye hiçbir şey olmadı, o degismeden kaldı. Aynı şekilde 5. özellikte X hiç degismeden esitliğin sagına aktarıldı sanki, sadece “ Z durumu için” yeni bir terim ekledik.

4. ve 5. ozellik cok onemlidir, bunlari bilerseniz bir ton hesabi yapmadan hizlica tureterek hesaplarinizi kolaylastirabilirsiniz.

Ozellik 6

$$\text{Cov}(X + Y, Z + W) = \text{Cov}(X, Z) + \text{Cov}(X, W) + \text{Cov}(Y, Z) + \text{Cov}(Y, W)$$

Simdi 5. ozelligi hatirlayalim, orada gosterilen sanki bir nevi basit cebirdeki dagitimsal (distributive) kuralin uygulanmasi gibiydi sanki, yani $(a + b)(c + d)$ 'i actigimiz gibi, 5. ozellik te sanki kovaryansi carpip topluyormus gibi "aciyordu". En temelde gercekten olan bu degil ama nihai sonuc benzer gozuktugu icin akilda tutmasi kolay bir metot elde etmis oluyoruz. Her neyse, 6. ozellik icin aslinda 5. ozelligi tekrar tekrar uygulamak yeterli. Bu arada 5. ozellik $\text{Cov}(X, Y + Z)$ icin ama $\text{Cov}(Y + Z, X)$ yine ayni sonucu veriyor.

Bu arada 6. ozellik cok cetrefil toplamlar uzerinde de uygulanabilir, mesela

$$\text{Cov}\left(\sum_{i=1}^m a_i X_i, \sum_{j=1}^n b_j Y_j\right)$$

Bu son derece karmasik gozukuyor, fakat cozumu icin aynen 6. ozellikte oldugu gibi 5. ozelligi yine tekrar tekrar uygulamak yeterli (4. ozellik ile de sabiti disari cikaririz, vs).

Cogu zaman ustteki gibi pur kovaryans iceren bir acilimla calismak, icinde bek-lentiler olan formullerle ugrasmaktan daha kolaydir.

Simdi toplamlara donelim; kovaryanslara girmemizin bir sebebi toplamlarla is yapabilmemizi saglamasi. Mesela, bir toplamın varyansini nasil hesaplariz?

Ozellik 7

$$\text{Var}(X_1 + X_2)$$

Simdilik iki degisken, ama onu genellestirip daha fazla degiskeni kullanabiliriz.

Cozelim. 1. ozellik der ki varyans degiskenin kendisi ile kovaryansidir, yani $\text{Var}(X) = \text{Cov}(X, X)$. O zaman $\text{Var}(X_1 + X_2) = \text{Cov}(X_1 + X_2, X_1 + X_2)$. Boylece icinde toplam iceren bir kovaryans elde ettik ama bunu cozmeyi biliyoruz artik. "Dagitimsal" islemleri yaparken $\text{Cov}(X_1, X_1)$ gibi ifadeler cikacak, bunlar hemen varyansa donusecek. Diger taraftan $\text{Cov}(X_1, X_2)$ iki kere gelecek, yani

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2) + 2\text{Cov}(X_1, X_2)$$

Bu alanda bilinen tekerleme gibi bir baska deyiş, "eger kovaryans sifirsa toplamın varyansı varyansların toplamıdır". Hakikaten kovaryans sifir olunca ustteki den-klem den duşecektir, geriye sadece varyansların toplamı kalacaktır. Kovaryans ne

zaman sifirdir? Eger X_1, X_2 birbirinden bagimsiz ise. Tabii bu bagimsizlik her zaman ortaya cikmaz.

Ikiden fazla degisken olunca? Yine tum varyanslarin ayri ayri toplami, ve kovaryanslar da sonda toplanacak,

$$\text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n) + 2 \sum_{i < j} \text{Cov}(X_i, X_j)$$

Sondaki toplamın indisinde bir numara yaptık, sadece 1 ile 2, 2 ile 3, vs. eslemek için, ve mesela 3 ile 1'i tekrar eslememek için. Tekrar dedik çünkü $\text{Cov}(X_1, X_3) = \text{Cov}(X_3, X_1)$. Eger indisleme numarasi kullanmasaydik, 2 ile carpimi cikartirdik (ona artik gerek olmazdi),

$$\dots + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

Simdi, korelasyon konusuna gelmeden once, bagimsizlik kavramini iyice anladigimizdan emin olalim. a

Teori

Eger X, Y bagimsiz ise bu degiskenler bagimsizdir, yani $\text{Cov}(X, Y) = 0$.

DIKKAT! Bu mantik cizgisinin tersi her zaman dogru olmayabilir, yani bagimsizlik kesinlikle $\text{Cov}(X, Y) = 0$ demektir, ama her $\text{Cov}(X, Y) = 0$ oldugu zaman ortada bir bagimsizlik var diyemeyiz. Bunu bir ornekle gorelim.

$$Z \sim N(0, 1), X = Z, Y = Z^2$$

Simdi X, Y kovaryansinin hesabi yapalim

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = E(Z^3) - E(Z)E(Z^2)$$

En sondaki terim sifirdir, çünkü hem $E(Z)$ ve $E(Z^3)$ sifirdir [hoca burada standart normalin tek sayili (odd) moment'leri hep sifirdir dedi]. O zaman su sonucu cikartiyoruz, X, Y arasinda korelasyon yok.

Ama bagimlilik var mi? Var. Çünkü hem X hem Y Z 'nin birer degiskeni, yani bu durumda X 'i bilmek bize Y 'yi tamamen bilmemizi sagliyor (sadece ek olarak bir kare aliyoruz). Tabii bagimlilik illa herseyin bilinmesi demek degildir, biraz bagimlilik ta olabilir, ama biraz bagimlilik bile varsa, bagimsizlik var diyemeyiz. Ayni sey ters yon için de gecerli, Y bilinince X 'in "buyuklugunu" bilebiliriz, karekok islemi oldugu için $-/+$ isareti bilemeyiz ama skalar bir buyuklugu elde edebiliriz. Yani ters yonde de bagimsizlik yoktur.

Korelasyon

Tanim

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\text{SD}(X)\text{SD}(Y)} \quad (2)$$

Bu arada hatirlarsak ustte SD ile gosterilen standart sapma, varyansin karesidir.

Bu tanim genelde kullanılan tanimdir. Fakat ben daha farkli bir tanimi tercih ediyorum. Standardize etmeyi hatirliyoruz degil mi? Bir rasgele degiskenden ortalamasini cikartip standart sapmaya bolunce standardize ediyorduk. Bunu kullanarak aslinda korelasyonu alttaki gibi tanimlayabiliriz,

$$\text{Corr}(X, Y) = \text{Cov}\left(\frac{X - E(X)}{\text{SD}(X)}, \frac{Y - E(Y)}{\text{SD}(Y)}\right) \quad (3)$$

Yani korelasyonun anlami aslinda sudur: X, Y degiskenlerini standardize et, ondan sonra kovaryanslarini al.

Niye kovaryans iceren ifadeyi tercih ediyoruz? Cunku, diyelim ki X, Y degiskenleri bir uzaklik olcusunu temsil ediyor, ve birimleri mesela nanometre. Fakat bir baskasi gelip ayni olcumu, atiyorum, isik yili olarak kullanmaya baslarsa problem cikabilir. Yani eger birim yoksa ve ben " X, Y korelasyonum 42" dersem, bunun ne oldugunu anlamak zordur. 42 onumuzdeki veriye gore kucuk mudur, buyuk mudur? Bilemeyiz. Yani 42 sayisi tabii ki evrendeki tum sorularin cevabidir [hoca bir filme atfen espri yapiyor, orada 42 sayisinin ozel bir anlami vardi], ama onumuzdeki problem icin, nedir?

Fakat ustteki formül olcu birimsiz (dimensionless) bir sonuc verir, yani bir olcu biriminden bahsetmeden birine rahatca aktarabilecegimiz bir bilgidir. Niye birimsiz oldu? Cunku X 'in birimi cm olsa, $X - E(X)$ yine cm, $\text{SD}(X)$ varyansin karekoku oldugu icin cm^2 'nin karekoku yine cm, cm bolu cm birim ortadan kalkar.

Bu arada (3) niye (2) ile aynidir? Eger bir rasgele degiskenden bir sabiti cikartirsam onun baska bir degisken ile kovaryansini degistirmis olmam. Ki standardize etme islemi bunu yapar. O zaman niye bu cikartma islemini yaptim? Cunku standardize etme islemini ozellikle kullanmak istedim - standardizasyon bilinen ve rahatca kullanilabilen bir islem. Standart sapmayi bolmeye gelirse, simdiye kadar gordugumuz ozelliklerden biri, bolumu disari alabilecegimizi gosteriyor, boyle olunca (2) ifadesini aynen elde ediyorum.

[Not: cok ilginç bir noktaya isaret etmek isterim. Hoca X, Y 'yi standardize etti, ama bu demek degil ki X, Y "standard normal" dagilimi haline geldi, X, Y 'in eger kendileri normal olsaydi o zaman standart normal elde ederdik. Diger durumlarda X, Y 'yi ortalamasi 0, varyansi 1 olan bir sey haline getirmis olduk sadece. Ama yine bu dusunceden devam edersek, eger X, Y normal olsaydi, standardize bize iki tane Z verirdi, ve $\text{Cov}(Z, Z) = 1$ olurdu. Yani hangi sekilde olursa olsun eger X, Y 'nin ikisi de normal ise korelasyon 1 demektir].

Onemli bir nokta daha: korelasyon her zaman -1 ve $+1$ arasindadir.

Teori

$$-1 \leq \text{Corr}(X, Y) \leq 1$$

Yani olcu biriminden bagimsiz olmasi avantajina ek olarak hep ayni skalada olan bir degerin rapor edilmesi de faydalidir. Eger korelasyon 0.99 bulursam bunun hemen yuksek bir korelasyon oldugunu bilirim.

Bu arada, Cauchy-Schwarz esitsizliginden bahsedeyim -ki bu esitsizlik tanimi tum matematikteki en onemli esitsizliklerden biridir- eger korelasyon formülünü lineer cebirsel sekilde ifade etseydim direk Cauchy-Schwarz esitsizligini elde ederdim.

Ispat

Once “WLOG cercevesinde” X, Y ’nin onceden standardize edilmiş oldugunu kabul edelim. [WLOG ne demek? Matematikciler ispatlar sirasinda bunu bazen kullanirlar, genelleme kuvvetinde bir kayip olmadan (without loss of generality) takip eden seyi kullanabiliriz demektir, yani “bir baska sey kullaniyorum, ama teori bu cercevede de hala gecerli” demek isterler].

Onceden standardize edildigini kabul etmek niye fark yaratmiyor? Cunku bunu gorduk, standart olmayan degiskenleri standardize edince yine ayni sonucu elde ediyorum, yani bir sey farketmiyor.

$\text{Var}(X + Y)$ ’i hesaplayalim.

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) \quad (4)$$

Simdi sembol olarak $\rho = \text{Corr}(X, Y)$ kullanalim,

Standardize ettigimizi kabul etmistik, o zaman $\text{Var}(X) = 1, \text{Var}(Y) = 1$. Ayrica (3)’te gordugumuz uzere, standardize durumda kovaryans korelasyona esittir, o zaman $\text{Cov}(X, Y) = \rho$, yani $2\text{Cov}(X, Y) = 2\rho$. Tum ifade,

$$\text{Var}(X + Y) = 1 + 1 + 2\rho = 2 + 2\rho$$

Peki farklari varyansi, $\text{Var}(X - Y)$ nedir? Bir numara kullanalim, $\text{Var}(X - Y)$ ’i $\text{Var}(X + (-Y))$ olarak gorelim,

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y) = 2 - 2\rho$$

Aslinda bu son ifade ispati tamamlamis oldu, cunku varyans negatif olmayam bir seydir, yani

$$0 \leq \text{Var}(X + Y) = 2 + 2\rho$$

$$0 \leq \text{Var}(X - Y) = 2 - 2\rho$$

Bu iki esitsizligi kullanarak

$$-2 \leq 2\rho$$

$$-2 \leq -2\rho$$

ve

$$-1 \leq \rho$$

$$\rho \leq 1$$

Multinom Dagilimin Kovaryansi

Kovaryansi multinom dagilimi baglaminda ele alalim, bildigimiz gibi multinom dagilimi bir vektordur [ve binom dagiliminin daha yuksek boyuttaki halidir, binom dagilimi bildigimiz gibi n deney icinde kac tane basari sayisi oldugunu verir], ve vektorun her hucresinde “vs. kategorisinde kac tane vs var” gibi bir deger tasinir, ki bu her hucre baglaminda “o kategori icin zar atilrsa kac tane basari elde edilir” gibi okunabilir.

Biz ise bu hucrelerden iki tanesini alip aralarindaki kovaryasyona bakmak istiyoruz. Gayet dogal bir istek.

Notasyon

Elimizde k tane obje var,

$$(X_1, \dots, X_k) \sim \text{Mult}(n, \vec{p})$$

Dikkat, p bir vektor, tabii ki, cunku binom durumunda p tek sayi idi, simdi “pek cok p ”ye ihtiyac var.

Her i, j icin $\text{Cov}(X_i, X_j)$ ’yi hesapla.

Eger $i = j$ ise $\text{Cov}(X_i, X_i) = \text{Var}(X_i) = np_i(1 - p_i)$.

ki son ifade binom dagiliminin varyansidir. Bu basit durum tabii ki, ilginç olan $i \neq j$ olmadigi zaman.

Tek ornek secelim, mesela $\text{Cov}(X_1, X_2)$, buradan gelen sonuc gayet kolayca genellestirilebilir.

Hesaba baslamadan once kabaca bir akil yurutelim; $\text{Cov}(X_1, X_2)$ icin arti mi eksi mi bir deger elde ederdik acaba? Multinom dagilimi hatirlayalim, belli sayida "sey" yine belli sayida kategori arasinda "kapisiliyor", yani bu kategoriler arasinda bir yaris var. O zaman herhangi iki kategorinin kovaryansinin negatif olmasini bekleriz.

Cozum icin (4) formulunu kullanacagim, ama secici bir sekilde,

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

icinde $\text{Var}(X+Y)$, $\text{Var}(X)$, $\text{Var}(Y)$ 'i biliyorsam, geriye bilinmeyen $\text{Cov}(X, Y)$ kalir. Kisaltma amaciyla $c = \text{Cov}(X, Y)$ diyelim,

$$\text{Var}(X_1 + X_2) = np_1(1 - p_1) + np_2(1 - p_2) + 2c$$

Simdi $X_1 + X_2$ 'nin ne oldugunu dusunelim, bu yeni rasgele degisken "ya kategori 1 ya da 2" sonucunu tasiyan bir degiskendir, ki bu da yeni bir "birlesik" binom degiskenidir. Bu degiskenin p 'si toplami oldugu iki kategorinin p 'sinin toplamidir, yani $p_1 + p_2$. O zaman bu yeni degiskenin varyansi,

$$\text{Var}(X_1 + X_2) = n(p_1 + p_2)(1 - (p_1 + p_2))$$

Eh artik denklemdaki her seyi biliyoruz, sadece c 'yi bilmiyoruz, ona gore herseyi duzenleyelim,

$$n(p_1 + p_2)(1 - (p_1 + p_2)) = np_1(1 - p_1) + np_2(1 - p_2) + 2c$$

Burada biraz haldir huldur islem lazim [bu kısmi okuyucu isterse yapabilir], sonuc

$$\text{Cov}(X_1, X_2) = -np_1p_2$$

Genel olarak

$$\text{Cov}(X_i, X_j) = -np_i p_j, \forall i \neq j$$

Dikkat edin, bu sonuc her zaman negatiftir (cunku p degerleri olasilik degerleridirler, yani pozitif olmak zorundadirlar)

Ornek

Binom degiskenin varyansini hesaplayalim simdi. Bunu daha once yapmistik ama gostergec (indicator) rasgele degiskenleri kullanarak yapmistik bunu, simdi elimizde yeni bir arac var, onu kullanalim. Varacagimiz sonuc $\text{Var}(X) = npq$ olacak. Tanimlar,

$$X \sim \text{Bin}(n, p), X = X_1 + \dots + X_n$$

ki X_i degiskenleri i.i.d. Bernoulli.

Aslinda her X_i degiskeni bir gostergec degiskeni gibi gorulebilir. Diyelim ki bir A olayi icin gostergec degisken I_A olsun. Bu durumda

$$I_A^2 = I_A$$

$$I_A^3 = I_A$$

Degil mi? Gostergec sadece 1/0 olabiliyorsa onun karesi, kupu ayni sekilde olur. Bunu vurguluyorum, cunku bazen atlaniyor.

Peki $I_A I_B$? Ki A, B ayri ayri olaylar. Gayet basit,

$$I_A I_B = I_{A \cap B}$$

Bu normal degil mi? Esitligin solundaki carpim sadece her iki degisken de 1 ise 1 sonucunu verir, bu ise sadece A, B olaylari ayni anda oldugu zaman mumkundur, ki bu ayni anda olmak kume kesismesinin tanimidir.

Bernoulli durumuna donelim, her Bernoulli icin

$$\text{Var}(X_i) = EX_j^2 - E(X_j)^2$$

$X_j^2 = X_j$ 'dir, bunu biraz once gorduk, ve Binom degiskenleri gostergec gibi goruyoruz, o zaman $EX_j^2 = E(X_j) = p$.

$$\text{Var}(X_i) = p - p^2 = p(1 - p) = pq$$

Tum binom dagilimin varyansi,

$$\text{Var}(X) = npq$$

Bu kadar basit. Cunku $\text{Cov}(X_i, X_j) = 0, \forall i \neq j$, yani her bernoulli deneyi birbirinden bagimsiz, o sebeple binom varyansi icin tum bernoulli varyanslarini

toplamak yeterli, eger varyansi pq olan n tane bernoulli varsa, binom varyansi npq .

Ornek

Daha zor bir ornegi gorelim.

$$X \sim \text{HGeom}(w, b, n)$$

Bu bir hipergeometrik dagilim. Parametreleri soyle yorumlayabiliriz, bir kutu icinde w tane beyaz top var, b tane siyah top var, ve biz bu kutudan n buyuklugunde bir orneklem aliyoruz, ve ilgilendigimiz orneklemdaki beyaz toplarin dagilimi.

[dersin gerisi atlandi]

Verisel Kovaryans (Empirical Covariance)

Eger verinin kolonlari arasindaki iliskiyi gormek istersek, en hizli yontem matristeki her kolonun (degiskenin) ortalamasini kendisinden cikartmak, yani onu "sifirda ortalamak" ve bu matrisin devrigini alarak kendisi ile carpma. Bu islem her kolonu kendisi ve diger kolonlar ile noktasal carpimdan gecirecektir ve carpim, toplama sonucunu nihai matrise yazacaktır. Carpimlarin bildigimiz ozelligine gore, arti deger arti degerle carpilince arti, eksi ile eksi arti, eksi ile arti eksi verir, ve bu bilgi bize ilinti bulma hakkında guzel bir ipucu sunar. Pozitif sonucun pozitif korelasyon, negatif ise tersi sekilde ilinti oldugu sonucuna boylece kolayca erisebiliriz.

Tanim

$$S = \frac{1}{n}(X - E(X))^T(X - E(X))$$

Pandas ile `cov` cagrisi bu hesabi hizli bir sekilde yapar,

```
print df.cov()
```

	Sepal Length	Sepal Width	Petal Length	Petal Width
Sepal Length	0.685694	-0.039268	1.273682	0.516904
Sepal Width	-0.039268	0.188004	-0.321713	-0.117981
Petal Length	1.273682	-0.321713	3.113179	1.296387
Petal Width	0.516904	-0.117981	1.296387	0.582414


Eger kendimiz bu hesabi yapmak istersek,

```
means = df.mean()
n = df.shape[0]
df2 = df.apply(lambda x: x - means, axis=1)
print np.dot(df2.T, df2) / n
```

```
[[ 0.68112222 -0.03900667  1.26519111  0.51345778]
 [-0.03900667  0.18675067 -0.319568   -0.11719467]
 [ 1.26519111 -0.319568    3.09242489  1.28774489]
 [ 0.51345778 -0.11719467  1.28774489  0.57853156]]
```

Verisel kovaryansin sayisal gosterdigini grafiklemek istersek, yani iki veya daha fazla boyutun arasindaki iliskileri grafiklemek icin yontemlerden birisi verideki mumkun her ikili iliskiye grafiksel olarak gostermeektir. Pandas `scatter_matrix` bunu yapabilir. Iris veri seti uzerinde gozelim, her boyut hem y-ekseni hem x-ekseninde verilmiş, iliskiye gormek icin eksende o boyutu bulup kesisme noktalarindaki grafige bakmak lazim.

```
import pandas as pd
df = pd.read_csv('iris.csv')
df = df.ix[:,0:4]
pd.scatter_matrix(df)
plt.savefig('stat_summary_01.png')
```



Iliski oldugu zaman o iliskiye tekabul eden grafikte “düz çizgiye benzer” bir görüntü olur, demek ki değişkenlerden biri artınca diğeri de artıyor (eger çizgi soldan sağa doğru doğru gidiyorsa), azalınca diğeri de azalıyor demektir (eger çizgi aşağı doğru iniyorsa). Eger ilinti yok ise bol gürültülü, ya da yuvarlak kur-eye benzer bir şekil çıkar. Üstteki grafiğe göre yaprak genişliği (petal width) ile yaprak boyu (petal length) arasında bir ilişki var.

Tanim

X,Y rasgele değişkenlerin arasindaki kovaryans,

$$\text{Cov}(X, Y) = E(X - E(X))(Y - E(Y))$$

Yani hem X hem Y'nin beklentilerinden ne kadar saptıklarını her veri ikilisi için,

cikartarak tespit ediyoruz, daha sonra bu farklari birbiriyle carpiyoruz, ve beklentisini aliyoruz (yani tum olasilik uzerinden ne olacagini hesapliyoruz).

Ayri ayri X, Y degiskenleri yerine cok boyutlu X kullanirsak, ki boyutlari m, n olsun yani m veri noktası ve n boyut (ozellik, oge) var, tanimi soyle ifade edebiliriz,

$$\Sigma = \text{Cov}(X) = E((X - E(X))^T (X - E(X)))$$