

Orneklem Buyuklugu

Bir arastirmaci n bagimsiz deney baz alinarak elde edilen binom parametresi p 'yi tahmin etmek istiyor, fakat kac tane n kullanmasi gerektigini bilmiyor. Tabii ki daha buyuk n degerleri daha iyi sonuclar verecektir, ama her deneyin bir masrafi vardır. Bu iki gereklilik nasil birbiri ile uzlastirilir?

Yeterli olacak en az kesinligi, duyarlilik (precision) bulmak icin Z transformasyonu kullanilabilir belki. Diyelim ki p icin maksimum olurluk tahmini olan X/n 'in en azindan $100(1 - \alpha)\%$ olasilikta p 'nin d kadar yakininda olmasini istiyoruz. O zaman alttaki denklemi tatmin eden en ufak n 'i buldugumuz anda problemimizi cozduk demektir,

$$P\left(-d \leq \frac{X}{n} - p \leq d\right) = 1 - \alpha \quad (1)$$

Tahmin edici X/n 'nin kendisi de bir rasgele degiskendir. Bu degisken normal olarak dagilmistir, cunku X Binom olarak dagilmis ise, bu dagilim ayri Bernoulli dagilimlerinin toplamina esittir. Fakat baska bir irdeleme bizi daha basitce sonuca goturur, binom dagilimi bir toplamdir, bu toplami, yani X 'i n ile boluyorsak, otomatik olarak bir aritmetik averaj islemi yapmis oluyoruz. Ayni bagimsiz ayri (iid) rasgele degiskenlerin aritmetik ortalamasi Merkezi Limit Kanunu'na gore normal'e yaklastigina gore o zaman, elimizde bir normal dagilim var demektir.

Standardize etmek icin X/n 'den beklentiye cikartip standart sapmaya bolebiliriz. Beklenti zaten cikartilmis durumda (sansa bak!), beklentinin ne oldugunu kontrol edelim tabii, ezbere yapmayalim bu isi, eger her Bernoulli'yi X_i olarak temsil edersek,

$$X = X_1 + \dots + X_n$$

$$X/n = 1/n(X_1 + \dots + X_n)$$

$$E[X/n] = E[1/n(X_1 + \dots + X_n)]$$

$$= 1/nE[(X_1 + \dots + X_n)]$$

$$= (1/n)np = p$$

Varyans icin

$$\text{Var}(X/n) = \frac{1}{n^2}\text{Var}(X) = \frac{1}{n^2}np(1-p) = \frac{1}{n}p(1-p)$$

Binom dagilimlar icin $\text{Var}(X) = np(1 - p)$ oldugunu biliyoruz. Standart sapma ustteki ifadenin karekoku, yani

$$\text{Std}(X/n) = \sqrt{p(1 - p)/n}$$

Simdi standardize edelim,

$$P\left(\frac{-d}{\sqrt{p(1 - p)/n}} \leq \frac{\frac{X}{n} - p}{\sqrt{p(1 - p)/n}} \leq \frac{d}{\sqrt{p(1 - p)/n}}\right) = 1 - \alpha$$

$$P\left(\frac{-d}{\sqrt{p(1 - p)/n}} \leq Z \frac{d}{\sqrt{p(1 - p)/n}}\right) = 1 - \alpha$$

Daha onceki z-skoru iceren esitsizlikleri hatirlarsak, ustteki ifade

$$\frac{d}{\sqrt{p(1 - p)/n}} = z_{\alpha/2}$$

O zaman

$$\frac{z_{\alpha/2}^2 p(1 - p)}{d^2} = n$$

Fakat bu bir nihai sonuc olamaz, cunku n , p 'nin bir fonksiyonun haline geldi ve p bilinmeyen bir deger. Fakat biliyoruz ki $0 \leq p \leq 1$, ve $p(1 - p) \leq \frac{1}{4}$. Yani bir ust sinir (upper bound) elde ettik.

Bunu kontrol edelim, $p(1 - p)$ hangi p 'de maksimize olur? p 'ye gore turev aliriz, sifira esitleriz, $(p - p^2)' = 1 - 2p = 0$, $p = 1/2$. Ve hesabi yaparsak, $1/2(1 - 1/2) = 1/4$. Demek ki $p(1 - p)$ degeri $1/4$ 'ten daha buyuk olamaz. Buna gore, ustteki formule $p(1 - p)$ yerine onun olabilecegi en buyuk degeri koyarsak,

$$\frac{z_{\alpha/2}^2 1/4}{d^2} = n$$

$$n = \frac{z_{\alpha/2}^2}{4d^2}$$

Not: $p(1 - p)$, $1/4$ degerinden daha kucuk olabilir mi? Olabilir. Bu durumda n ustteki formulden elde edebilecegimiz degerden daha kucuk te cikabilecektir. Fakat $p(1 - p)$ 'in olabilecegi en buyuk deger $1/4$ 'u kullanarak " n 'in bundan daha buyuk olmasina gerek yok" diyebilen bir formule erismis olduk, yani, aslinda n icin bir ust sinir elde ettik.

Ornek

Buyuk bir sehirde cocuklarin kacta kacinin asisini almisi olup olmadigini anlamak icin bir anket gerceklestirilecek. Anketi duzenleyenler orneklem orani olan X/n 'in en az 98% oranda gercek oran p 'nin 0.05 yakininda olmasini istiyorlar. Orneklem ne kadar buyuk olmalidir?

Burada $100(1 - \alpha) = 98$, o zaman $\alpha = 0.02$, demek ki $z_{\alpha/2} = z_{0.02/2} = z_{0.01}$ degerine ihtiyacimiz var. Python ile

```
from scipy.stats.distributions import norm
print norm.ppf(0.99)
```

2.32634787404

Tum hesap icin

$$n = \frac{(2.33)^2}{4(0.05)^2} = 543$$

Demek ki kabul edilebilir en ufak deger 543.