

Ozet Istatistikleri, Grafikleri

Beklenti (Expectation)

Bu deger, dagilim $f(x)$ 'in tek sayilik bir ozetidir. Yani beklenti hesabina bir taraftan bir dagilim fonksiyonu girer, diger taraftan tek bir sayi disari cikar.

Tanim

Surekli dagilim fonksiyonlari icin $E(X)$

$$E(X) = \int xf(x)dx$$

ayriksal dagilimlar icin

$$E(X) = \sum_x xf(x)$$

Hesabin, her x degerini onun olasiligi ile carpip topladigina dikkat. Bu tur bir hesap dogal olarak tum x 'lerin ortalamasini verecektir, ve dolayli olarak dagilimin ortalamasini hesaplayacaktır. Ortalama μ_x olarak ta gosterilebilir.

$E(X)$ 'in bir tanim olduguna dikkat, yani bu ifade tamamen bizim yarattigimiz, ortaya cikarttigimiz bir sey, matematigin baz kurallarindan gelerek turetilen bir kavram degil.

Notasyonel basitlik icin ustteki toplam / integral yerine

$$= \int x dF(x)$$

diyecegiz, bu notasyonel bir kullanim sadece, unutmayalim, reel analizde $\int x dF(x)$ 'in ozel bir anlami var (hoca tam diferansiyel dF 'den bahsediyor).

Beklentinin taniminin kapsamli / eksiksiz olmasi icin $E(X)$ 'in "mevcudiyeti" icin de bir sart tanımlamak gerekir, bu sart soyle olsun,

$$\int_x |x|dF_X(x) < \infty$$

ise beklenti mevcut demektir. Tersi sozkonusu ise beklenti mevcut degildir.

Ornek

$X \sim \text{Unif}(-1, 3)$ olsun. $E(X) = \int x dF(x) = \int xf_X(x)dx = \frac{1}{4} \int_{-1}^3 xdx = 1$.

Ornek

Cauchy dagiliminin $f_X(x) = \{\pi(1+x^2)\}^{-1}$ oldugunu soylemistik. Simdi beklentiyi hesaplayalim. Parcali entegral teknigi lazim, $u = x$, $dv = 1/(1+x^2)$ deriz, ve o zaman $v = \tan^{-1}(x)$ olur, bkz *Ters Trigonometrik Formuller* yazimiz. Demek ki

$$\int |x|dF(x) = \frac{2}{\pi} \int_0^{\infty} \frac{x dx}{1+x^2}$$

2 nereden cikti? Cunku $|x|$ kullaniyoruz, o zaman sinir degerlerinde sadece sifirin sagina bakip sonucu ikiyle carpma yeterli. Bir sabit oldugu icin π ile beraber disari cikiyor. Simdi

$$\int u dv = uv - \int v du$$

uzerinden

$$= [x \tan^{-1}(x)]_0^{\infty} - \int_0^{\infty} \tan^{-1}(x) dx = \infty$$

Yani ustteki hesap sonsuzluga gider. O zaman ustteki tanimimiza gore Cauchy dagiliminin beklentisi yoktur.

Tanim

x_1, \dots, x_n verilerini iceren orneklemen (sample) ortalamasi

$$\bar{x} = \frac{1}{n} \sum x_i \quad (1)$$

Dikkat bu orneklemdeki verinin ortalamasi. Hicbir dagilim hakkında hicbir faraziye yapmadik. Ayrica tanim kullandik, yani bu ifadenin ne oldugu tamamen bize bagli.

Orneklem ortalamasi sadece tek merkezi bir tepesi olan (unimodal) dagilimlar icin gecerlidir. Eger bu temel varsayim gecerli degilse, ortalama kullanarak yapilan hesaplar bizi yanlis yollara goturur. Ayrica bir dagilimi simetrik olup olmadigi da ortalama ya da medyan kullanilip kullanilmamasi kararinda onemlidir. Eger simetrik, tek tepeli bir dagilim var ise, ortalama ve medyan birbirine yakin olacaktir. Fakat veri baska turde bir dagilim ise, o zaman bu iki olcut birbirinden cok farkli olabilir.

Tanim

Y rasgele degiskeninin varyansi (variance)

$$\text{Var}(Y) = E((Y - E(Y))^2)$$

Ifadede toplama ve bolme gibi islemler olmadigina dikkat; onun yerine kare ifadeleri uzerinde beklenti ifadesi var. Yani Y 'nin beklentisini rasgele degiskenin kendisinden cikartip kareyi aliyoruz, ve bu islemin Y 'den gelen tum zar atislari uzerinden beklentisi bize varyansi veriyor. Bir rasgele degisken gorunce onun yerine "dagilimdan uretilen sayi" dusunmek faydalidir, ki bu gercek dunya sart-larindan (ve buyuk miktarda olunca) veri noktalarini temsil eder.

Varyans formulu acarsak, ileride isimize yarayacak baska bir formül elde ede-biliriz,

$$\text{Var}(Y) = E(Y^2 - 2YE(Y) + (E(Y)^2))$$

$$= E(Y^2) - 2E(Y)E(Y) + (E(Y)^2)$$

$$\text{Var}(Y) = E(Y^2) - (E(Y)^2)$$

Tanim

y_1, \dots, y_n orneklemnin varyansi (literaturde S^2 olarak gecebiliyor,

$$S^2 = \frac{1}{n} \sum (y_i - \bar{y})^2 \quad (2)$$

Standart sapma veri noktalarin "ortalamadan farkinin ortalamasini" verir. Tabii bazen noktalar ortalamamin altinda, bazen ustunde olacaktir, bizi bu negatiflik, pozitiflik ilgilendirmez, biz sadece farkla alakaliyiz. O yuzden her sapmanin karesini aliriz, bunlari toplayip nokta sayisina boleriz.

Ilginc bir cebirsel islem sudur ve bize verinin uzerinden tek bir kez gecerek (one pass) hem sayisal ortalamayi hem de sayisal varyansi hesaplamamizi saglar. Eger \bar{y} tanimini ustteki formule sokarsak,

$$\begin{aligned} &= \frac{1}{n} \sum_i y_i^2 + \frac{1}{n} \sum_i m^2 - \frac{2}{n} \sum_i y_i \bar{y} \\ &= \frac{1}{n} \sum_i y_i^2 + \frac{\bar{y}^2 n}{n} - \frac{2\bar{y}n}{n} \bar{y} \\ &= \frac{1}{n} \sum_i y_i^2 + \bar{y}^2 - 2\bar{y}^2 \\ &= \frac{1}{n} \sum_i y_i^2 - \bar{y}^2 \end{aligned}$$

Bu arada standard sapma varyansin karekokudur, ve biz karekok olan versiyon ile calismayi tercih ediyoruz. Niye? Cunku o zaman veri noktalarinin ve yayilma olcusunun birimleri birbiri ile ayni olacak. Eger veri setimiz bir alisveris sepetindeki malzemelerin lira cinsinden degerleri olsaydi, varyans bize sonucu "kare lira" olarak verecekti ve bunun pek anlami olmayacakti.

Kovaryans ve Korelasyon (Covariance and Correlation)

Verisel Kovaryans (Empirical Covariance)

Eger verinin kolonlari arasindaki iliskiye gormek istersek, en hizli yontem matristeki her kolonun (degiskenin) ortalamasini kendisinden cikartmak, yani onu "sifirda ortalamak" ve bu matrisin devrigini alarak kendisi ile carpmandir. Bu islem her kolonu kendisi ve diger kolonlar ile noktasal carpimdan gecirecektir ve carpim, toplama sonucunu nihai matrise yazacaktır. Carpimlari bildigimiz ozelligine gore, arti deger arti degerle carpilince arti, eksi ile eksi arti, eksi ile arti eksi verir, ve bu bilgi bize ilinti bulma hakkında guzel bir ipucu sunar. Pozitif sonucun pozitif korelasyon, negatif ise tersi sekilde ilinti oldugu sonucuna boylece kolayca erisebiliriz.

Tanim

$$S = \frac{1}{n}(X - E(X))^T(X - E(X))$$

Pandas ile `cov` cagrisi bu hesabi hizli bir sekilde yapar,

```
print df.cov()
```

	Sepal Length	Sepal Width	Petal Length	Petal Width
Sepal Length	0.685694	-0.039268	1.273682	0.516904
Sepal Width	-0.039268	0.188004	-0.321713	-0.117981
Petal Length	1.273682	-0.321713	3.113179	1.296387
Petal Width	0.516904	-0.117981	1.296387	0.582414


Eger kendimiz bu hesabi yapmak istersek,

```
means = df.mean()
n = df.shape[0]
df2 = df.apply(lambda x: x - means, axis=1)
print np.dot(df2.T, df2) / n
```

```
[[ 0.68112222 -0.03900667  1.26519111  0.51345778]
 [-0.03900667  0.18675067 -0.319568   -0.11719467]
 [ 1.26519111 -0.319568    3.09242489  1.28774489]
 [ 0.51345778 -0.11719467  1.28774489  0.57853156]]
```

Verisel kovaryansin sayisal gosterdigini grafiklemek istersek, yani iki veya daha fazla boyutun arasindaki iliskileri grafiklemek icin yontemlerden birisi verideki mumkun her ikili iliskiye grafiksel olarak gosterme'dir. Pandas `scatter_matrix` bunu yapabilir. Iris veri seti uzerinde gozelim, her boyut hem y-ekseni hem x-ekseninde verilmiş, iliskiye gormek icin ekseninde o boyutu bulup kesişme noktalarindaki grafiğe bakmak lazim.

```
import pandas as pd
df = pd.read_csv('iris.csv')
df = df.ix[:,0:4]
pd.scatter_matrix(df)
plt.savefig('stat_summary_01.png')
```



İliski olduğu zaman o ilişkiye tekabül eden grafikte “düz çizgiye benzer” bir görüntü olur, demek ki değişkenlerden biri artınca öteki de artıyor (eger çizgi soldan sağa yukarı doğru gidiyorsa), azalınca öteki de azalıyor demektir (eger çizgi aşağı doğru iniyorsa). Eger ilinti yok ise bol gürültülü, ya da yuvarlak kuryeye benzer bir şekil çıkar. Üstteki grafiğe göre yaprak genişliği (petal width) ile yaprak boyu (petal length) arasında bir ilişki var.

Tanım

X, Y rasgele değişkenlerin arasındaki kovaryans,

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y)))$$

Yani hem X hem Y’nin beklentilerinden ne kadar saptıklarını her veri ikilisi için, çıkartarak tespit ediyoruz, daha sonra bu farkları birbiriyle çarpıyoruz, ve beklentisini alıyoruz (yani tüm olasılık üzerinden ne olacağını hesaplıyoruz).

Ayrı ayrı X, Y değişkenleri yerine çok boyutlu X kullanırsak, ki boyutları m, n olsun yani m veri noktası ve n boyut (özellik, öge) var, tanımı şöyle ifade edebiliriz,

$$\Sigma = \text{Cov}(X) = E((X - E(X))^T(X - E(X)))$$

Medyan ve Yüzdelikler (Percentile)

Üstteki hesapların çoğu sayıları toplayıp, bölmek üzerinden yapıldı. Medyan ve

diğer yuzdeliklerin hesabi (ki medyan 50. yuzdelige tekabul eder) için eldeki tüm deęerleri "siraya dizmemiz" ve sonra 50. yuzdelik için ortadakine bakmamız gerekiyor. Mesela eğer ilk 5. yuzdeligi ariyorsak ve elimizde 80 tane deęer var ise, bastan 4. sayıya / vektor hucresine / ogeye bakmamız gerekiyor. Eđer 100 eleman var ise, 5. sayıya bakmamız gerekiyor, vs.

Bu siraya dizme islemi kritik. Kiyasla ortalama hesabi hangi sirada olursa olsun, sayıları birbirine topluyor ve sonra boluyor. Zaten ortalama ve sapmanın istatistikte daha çok kullanilmasının tarihi sebebi de aslında bu; bilgisayar öncesi çağda sayıları sıralamak (sorting) zor bir işti. Bu sebeple hangi sirada olursa olsun, toplayıp, bolerek hesaplanabilecek özetler daha makbuldu. Fakat artık sıralama islemi kolay, ve veri setleri her zaman tek tepeli, simetrik olmayabiliyor. Örnek veri seti olarak unlu `dellstore2` tabanındaki satış miktarları kullanırsak,

```
print np.mean(data)
```

```
213.948899167
```

```
print np.median(data)
```

```
214.06
```

```
print np.std(data)
```

```
125.118481954
```

```
print np.mean(data)+2*np.std(data)
```

```
464.185863074
```

```
print np.percentile(data, 95)
```

```
410.4115
```

Goruldugu gibi üç nokta hesabi için ortalamadan iki sapma ötesini kullanırsak, 464.18, fakat 95. yuzdeligi kullanırsak 410.41 elde ediyoruz. Niye? Sebep ortalamanın kendisi hesaplanırken çok üç deęerlerin toplama dahil edilmiş olması ve bu durum, ortalamanın kendisini daha büyük seviyeye doğru itiyor. Yuzdelik hesabi ise sadece sayıları sıralayıp belli bazı elemanları otomatik olarak üç nokta olarak addediyor.

Box Whisker Grafikleri

Tek boyutlu bir verinin dağılımını görmek için Box ve Whisker grafikleri faydalı araçlardır; medyan (median), dağılımın genişliğini ve sıradışı noktaları (outliers) açık şekilde gösterirler. İsim nereden geliyor? Box yani kutu, dağılımın ağırlığının nerede olduğunu gösterir, medyanın sağında ve solunda olmak üzere iki çeyreğin arasındaki kısımdır, kutu olarak resmedilir. Whiskers kedi kollarına verilen isimdir, zaten grafikte birazcık biyik gibi duruyorlar. Bu uzantılar medyan noktasından her iki yana kutunun iki kati kadar uzatılır sonra verideki


”ondan az olan en büyük” noktaya kadar geri çekilir. Tüm bunların dışında kalan veri ise teker teker nokta olarak grafikte basılır. Bunlar siradisi (outlier) oldukları için daha az olmaları tahmin edilir.

BW grafikleri iki veriyi dağılımsal olarak karşılaştırmak için birebirdir. Mesela Larsen and Marx adlı araştırmacılar çok az veri içeren Quintus Curtius Snodgrass veri setinin değişik olduğunu ispatlamak için bir sürü hesap yapmışlardır, bir sürü matematiksel işleme girmişlerdir, fakat basit bir BW grafiği iki setin farklılığını hemen gösterir.

BW grafikleri iki veriyi dağılımsal olarak karşılaştırmak için birebirdir. Mesela Larsen and Marx adlı araştırmacılar çok az veri içeren Quintus Curtius Snodgrass veri setinin değişik olduğunu ispatlamak için bir sürü hesap yapmışlardır, bir sürü matematiksel işleme girmişlerdir, fakat basit bir BW grafiği iki setin farklılığını hemen gösterir.

Python üzerinde basit bir BW grafiği

```
spread= rand(50) * 100
center = ones(25) * 50
flier_high = rand(10) * 100 + 100
flier_low = rand(10) * -100
data = concatenate((spread, center, flier_high, flier_low), 0)
plt.boxplot(data)
plt.savefig('05_03.png')
```



Bir diğer örnek Glass veri seti üzerinde

```
data = loadtxt("glass.data", delimiter=",")
head = data[data[:,10]==7]
tableware = data[data[:,10]==6]
containers = data[data[:,10]==5]


print head[:,1]

data = (containers[:,1], tableware[:,1], head[:,1])
```

```
plt.yticks([1, 2, 3], ['containers', 'tableware', 'head'])

plt.boxplot(data, 0, 'rs', 0, 0.75)
plt.savefig('05_04.png')
```

[1.51131	1.51838	1.52315	1.52247	1.52365	1.51613	1.51602	1.51623
	1.51719	1.51683	1.51545	1.51556	1.51727	1.51531	1.51609	1.51508
	1.51653	1.51514	1.51658	1.51617	1.51732	1.51645	1.51831	1.5164
	1.51623	1.51685	1.52065	1.51651	1.51711]			



Parametre Tahmin Ediciler (Estimators)

Maksimum Olurluk (maximum likelihood) kavramini kullanarak ilginç bazı sonuçlara erismek mumkun; bu sayede dagilim fonksiyonlari ve veri arasinda bazi sonuclar elde edebiliriz. Maksimum olurluk nedir? MO ile verinin her noktasi teker teker olasilik fonksiyonuna gecilir, ve elde edilen olasilik sonuclari birbiri ile carpilir. Cogunlukla formül icinde bilinmeyen bir(kac) parametre vardir, ve bu carpim sonrasi, icinde bu parametre(ler) olan yeni bir formül ortaya cikar. Bu nihai formülün kısmi türevi alinip sifira esitlenince cebirsel bazı teknikler ile bilinmeyen parametre bulunabilir. Bu sonuc eldeki veri baglaminda en mumkun (olur) parametre degeridir. Oyle ya, mesela Gaussian $N(10,2)$ dagilimi var ise, 60,90 gibi degerlerin “olurlugu” dusuktur. Gaussin uzerinde ornek,

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}, x \in \mathbb{R}$$

Carpim sonrasi

$$\begin{aligned} f(x_1, \dots, x_n; \mu, \sigma) &= \prod \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x_i - \mu)^2 \right\} \\ &= \frac{(2\pi)^{-n/2}}{\sigma^n} \exp \left\{ -\frac{\sum (x_i - \mu)^2}{2\sigma^2} \right\} \end{aligned}$$

Ustel kisim $-n/2$ nereden geldi? Cunku bolen olan karekoku uste cikardik, boylece $-1/2$ oldu, n cunku n tane veri noktasi yuzunden formül n kere carpiliyor. Veri

noktaları x_i içinde. Eger log, yani \ln alırsak \exp' den kurtuluruz, ve biliyoruz ki log olurlugu maksimize etmek normal olurlugu maksimize etmek ile aynı şeydir, çünkü \ln transformasyonu monoton bir transformasyondur. Ayrıca olurluk içbükeydir (concave) yani kesin tek bir maksimumu vardır.

$$\ln f = -\frac{1}{2}n \ln(2\pi) - n \ln \sigma - \frac{\sum (x_i - \mu)^2}{2\sigma^2}$$

Turevi alıp sifıra esitleyelim

$$\frac{\partial(\ln f)}{\partial \mu} = \frac{\sum (x_i - \mu)^2}{2\sigma^2} = 0$$

$$\hat{\mu} = \frac{\sum x_i}{n}$$

Bu sonuç (1)'deki formül, yani örneklem ortalaması ile aynı! Fakat buradan hemen bir bağlantıya zıplamadan önce sunu hatırlayalım - örneklem ortalaması formülünü *biz* tanımladık. “Tanım” diyerek bir ifade yazdık, ve budur dedik. Şimdi sonradan, verinin dağılımının Gaussian olduğunu farzederek, bu verinin mümkün kılabileceği en optimal parametre değeri nedir diye hesap ederek aynı formüle eristik, fakat bu bir anlamda bir güzel raslantı oldu.. Daha doğrusu bu aynılık Gaussian / Normal dağılımlarının “normalliği” ile alakalı muhakkak, fakat örnekleme ortalaması hiçbir dağılım faraziyesi yapmıyor, herhangi bir dağılımdan geldiği bilinen ya da bilinmeyen bir veri üzerinde kullanılabilir. Bunu unutmayalım. İstatistikte matematiğin lakaytlasması (sloppy) kolaydır, o sebeple neyin tanım, neyin hangi faraziyeyle göre optimal, neyin nüfus (population) neyin örneklem (sample) olduğunu hep hatırlamamız lazım.

Devam edelim, maksimum olurluk ile $\hat{\sigma}$ hesaplayalım,

$$\frac{\partial(\ln f)}{\partial \sigma} = -\frac{n}{\sigma} + \frac{\sum (x_i - \mu)^2}{2\sigma^3} = 0$$

Cebirsel birkaç düzenleme sonrası ve μ yerine yeni hesapladığımız $\hat{\mu}$ kullanarak,

$$\hat{\sigma}^2 = \frac{\sum (x_i - \hat{\mu})^2}{n}$$

Bu da örneklem varyansı ile aynı!

Yansızlık (Unbiasedness)

Tahmin edicilerin kendileri de birer rasgele değişken olduğu için her örneklem için değişik değerler verirler. Diyelim ki θ için bir tahmin edici $\hat{\theta}$ hesaplıyoruz, bu $\hat{\theta}$ gerçek θ için bazı örneklem için çok küçük, bazı örneklem için çok büyük sonuçlar (tahminler) verebilecektir. Kabaca ideal durumun, az çıkan tahminlerin

cok cikan tahminleri bir sekilde dengelemesi oldugunu tahmin edebiliriz, yani tahmin edicinin uretecegi pek cok degerin θ 'yi bir sekilde "ortalamasi" iyi olacaktir.



Bu durumu soyle aciklayalim, madem tahmin ediciler birer rasgele degisken, o zaman bir dagilim fonksiyonlari var. Ve ustteki resimde ornek olarak $\hat{\theta}_1, \hat{\theta}_2$ olarak iki tahmin edici gosteriliyor mesela ve onlara tekabul eden yogunluklar $f_{\hat{\theta}_1}, f_{\hat{\theta}_2}$. Ideal durum soldaki resimdir, yogunlugun fazla oldugu yer gercek θ 'ya yakin olmasi. Bu durumu matematiksel olarak nasil belirtiriz? Beklenti ile!

Tanim

Y_1, \dots, Y_n üzerindeki θ tahmin edicisi $\hat{\theta}$ 'den alinmis rasgele orneklem. Eger tum θ 'lar icin $E(\hat{\theta}) = \theta$ ise, bu durumda tahmin edicinin yansiz oldugu soylenir.

Ornek olarak maksimum olurluk ile onceden hesapladigimiz $\hat{\theta}$ tahmin edicisine bakalim. Bu ifade

$$\hat{\sigma}^2 = \frac{1}{n} \sum (Y_i - \hat{\mu})^2$$

ya da

$$\hat{\sigma}^2 = \frac{1}{n} \sum_i (Y_i - \bar{Y})^2$$

ile belirtildi. Tahmin edici $\hat{\sigma}^2, \sigma^2$ icin yansiz midir? Tanimimiza gore eger tahmin edici yansiz ise $E(\hat{\sigma}^2) = \sigma^2$ olmalidir.

Not: Faydali olacak bazi esitlikler, daha onceden gordugumuz

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

ve sayisal ortalama \bar{Y} 'nin beklentisi $E(\bar{Y}) = E(Y_i)$, ve $\text{Var}(\bar{Y}) = 1/n \text{Var}(Y_i)$.

Baslayalim,

$$E(\hat{\sigma}^2) = E\left(\frac{1}{n} \sum_i (Y_i - \bar{Y})^2\right)$$

Parantez icindeki $1/n$ sonrasindaki ifadeyi acarsak,

$$\begin{aligned} \sum_i (Y_i - \bar{Y})^2 &= \sum_i (Y_i^2 - 2Y_i\bar{Y} + \bar{Y}^2) \\ &= \sum_i Y_i^2 - 2 \sum_i Y_i\bar{Y} + n\bar{Y}^2 \end{aligned}$$

$\sum_i Y_i$ 'nin hemen yaninda \bar{Y} goruyoruz. Fakat \bar{Y} 'nin kendisi zaten $1/n \sum_i Y_i$ demek degil midir? Ya da, toplam icinde her i icin degismeyecek \bar{Y} 'yi toplam disina cekersek, $\bar{Y} \sum_i Y_i$ olur, bu da $\bar{Y} \cdot n\bar{Y}$ demektir ya da $n\bar{Y}^2$,

$$\begin{aligned} &= \sum_i Y_i^2 - 2n\bar{Y}^2 + n\bar{Y}^2 \\ &= \sum_i Y_i^2 - n\bar{Y}^2 \end{aligned}$$

Dikkat, artik $-n\bar{Y}^2$ toplama isleminin *disinda*. Simdi beklentiye geri donelim,

$$= E\left(\frac{1}{n} \left(\sum_i Y_i^2 - n\bar{Y}^2 \right)\right)$$

$1/n$ disari cekilir, beklenti toplamdan iceri nufuz eder,

$$= \frac{1}{n} \left(\sum_i E(Y_i^2) - nE(\bar{Y}^2) \right)$$

Daha once demistik ki (genel baglamda)

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

Bu ornek icin harfleri degistirirsek,

$$\text{Var}(Y_i) = E(Y_i^2) - E(Y_i)^2$$

Yani

$$E(Y_i^2) = \text{Var}(Y_i) + E(Y_i)^2$$

$E(Y_i) = \mu$ oldugunu biliyoruz,

$$E(Y_i^2) = \text{Var}(Y_i) + \mu^2$$

Aynisini $E(\bar{Y}^2)$ için kullanırsak,

$$E(\bar{Y}^2) = \text{Var}(\bar{Y}) + E(\bar{Y})^2$$

$$E(\bar{Y}) = \mu,$$

$$E(\bar{Y}^2) = \text{Var}(\bar{Y}) + \mu^2$$

$$= \frac{1}{n} \left(\sum_i \text{Var}(Y_i) + \mu^2 - n(\text{Var}(\bar{Y}) + \mu^2) \right)$$

$\text{Var}(Y_i) = \sigma^2$, ve basta verdığımız eşitlikler ile beraber

$$= \frac{1}{n} \left(\sum_i (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right)$$

Tekrar hatırlatalım, \sum_i sadece ilk iki terim için geçerli, o zaman, ve sabit değerleri n kadar topladığımıza göre bu aslında bir çarpım işlemi olur,

$$= \frac{1}{n} \left(n\sigma^2 + n\mu^2 - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right)$$

$$= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2$$

$$= \sigma^2 - \frac{\sigma^2}{n}$$

$$= \frac{n\sigma^2}{n} - \frac{\sigma^2}{n}$$

$$= \frac{n\sigma^2 - \sigma^2}{n}$$

$$= \frac{\sigma^2(n-1)}{n}$$

$$= \sigma^2 \frac{n-1}{n}$$

Goruldugu gibi eristigimiz sonuc σ^2 degil, demek ki bu tahmin edici yansiz degil. Kontrol tamamlandi.

Fakat eristigimiz son denklem bize baska bir sey gosteriyor, eger ustteki sonucu $\frac{n}{n-1}$ ile carpsaydik, σ^2 elde etmez miydik? O zaman yanli tahmin ediciyi yansiz hale cevirme icin, onu $\frac{n}{n-1}$ ile carpariz ve

$$\begin{aligned} \frac{n}{n-1} \frac{1}{n} \sum_i (Y_i - \bar{Y})^2 \\ = \frac{1}{n-1} \sum_i (Y_i - \bar{Y})^2 \end{aligned}$$

Ustteki ifade σ^2 'nin yansiz tahmin edicisidir.

Hesap icin kullandiginiz kutuphanelerin yanli mi yansiz mi hesap yaptigini bilmek iyi olur, mesela Numpy versiyon 1.7.1 itibariyle yanli standart sapma hesabi yapıyor, fakat Pandas yansiz olani kullanıyor (Pandas versiyonu daha iyi)

```
import pandas as pd
arr = np.array([1,2,3])
print 'numpy', np.std(arr)
print 'pandas', float(pd.DataFrame(arr).std())

numpy 0.816496580928
pandas 1.0
```

Büyük Sayılar Kanunu (Law of Large Numbers)

Olasılık kuramında önemli matematiksel bir denklem, büyük sayılar kanunudur. Bu kanun, örneklem (sample) ile rasgele degiskenler, yani matematiksel olasilik dagilimlari olan dunya arasinda bir baglanti gorevi gorur.

Kanun kabaca bildigimiz günlük bir gercegin matematiksel ispatıdır da denebilir. Yazı-tura atarken yazı çıkma ihtimalinin 1/2 olduğunu biliyoruz (cunku zar atisini bir dagilim gibi goruyoruz). Herhalde çoğumuz da bu yazı-tura işleminin "bir çok kere" tekrarlandığı durumda, toplam sonucun aşağı yukarı yarısının yazı olacağını tahmin biliyoruz.

Matematiksel olarak, farzedelim ki her yazı-tura atışı bir deney olsun. Her ayrı deneyin sonucu X_1, X_2, \dots, X_n olarak rasgele değişkenlerle tanımlanmış olsun, bu degiskenlerin dagilimi ayni (cunku ayni zar), ama birbirlerinden bagimsizlar (cunku her deney digerinden alakasiz). Değişkenlerin sonucu 1 ya da 0 değeri taşıyacak, Yazı=1, Tura=0.

Buyuk Sayılar Kanunu tum bu deney sonuclarinin, yani rasgele degiskenlerin av-eraji alinirsa, yani $\bar{X} = X_1 + \dots + X_n$ ile, elde edilen sonucun X_i 'lerin (ayni olan) beklentisine yaklasacaginin soyler, yani n büyüdükçe \bar{X}_n 'in 1/2'ye yaklastığını ispatlar, yani $E[X_i] = 1/2$ degerine. Notasyonel olarak $E(X_i) = \mu$ olarak da gosterilebilir.

Formüsel olarak, herhangi bir $\epsilon > 0$ için,

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| \leq \epsilon) = 1$$

ya da

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \epsilon) = 0$$

ya da

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Burada ne soylandığına dikkat edelim, X_i dağılımı *ne olursa olsun*, yani ister Binom, ister Gaussian olsun, *örneklem* üzerinden hesaplanan sayısal ortalamanın (empirical mean) formüsel olasılık beklentisine yaklaştığını söylüyoruz! X_i 'ler en absürt dağılımlar olabilirler, bu dağılımların fonksiyonu son derece cetrefil, tek tepeli (unimodal) bile olmayabilir, o formüller üzerinden beklenti için gereken integralin belki analitik çözümü bile mevcut olmayabilir! Ama yine de ortalama, o dağılımların beklentisine yaklaşıacaktır. İstatistik ile olasılık teorisi arasındaki bu çok önemli bir bağlantıdır.

Sonuç şaşırtıcı, fakat bir ek daha yapalım, sezgisel (intuitive) olarak bakarsak aslında sonuç çok şaşırtıcı olmayabilir. Niye? Diyelim ki genel veri $N(\mu, \sigma^2)$ şeklinde bir Normal dağılımdan geliyor ve örneklem de bu sebeple aynı dağılıma sahip. Bu durumda örneklemdeki veri noktalarının μ 'ya yakın değerler olmasını beklemek mantıklı olmaz mı? Çünkü bu dağılım "zar atınca" ya da bir genel nüfustan bir "örnek toplayınca" (ki bunu bir anlamda istatistiksel bir zar atışı olarak görebiliriz) onu μ, σ^2 'e göre atacaktır. Örneklemi zar atışı sonuçları olarak gördüğümüze göre elde edilen verilerin bu şekilde olacağı şaşırtıcı olmamalı. Ve bu zar atışlarının ortalamasının, son derece basit bir aritmetik bir işlemle hesaplanıyor olsa bile, μ 'ye yaklaşması normal olmalı.

Bu arada, bu argümana tersten bakarsak Monte Carlo integralinin niye işlediğine görebiliriz (bkz *Monte Carlo, Entegraller, MCMC* yazısı).

Özellikle örneklem ile genel nüfus (population) arasında kurulan bağlantıya dikkat edelim. İstatistin önemli bir bölümünün bu bağlantı olduğu söylenebilir. Her örneklem, bilmediğimiz ama genel nüfusu temsil eden bir dağılımla aynı dağılıma sahip olan X_i 'dir dedik, ve bu aynılıktan ve bağımsızlıktan yola çıkarak bize genel nüfus hakkında bir ipucu sağlayan bir kanun geliştirdik (ve birazdan ispatlayacağız).

İspata başlayalım.

X_1, X_2, \dots, X_n bağımsız değişkenler olsun.

$$E(X_i) = \mu$$

$$\text{Var}(X_i) = \sigma$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

\bar{X}_n de bir rasgele deęiřkendir, ünkü \bar{X}_n deęiřkeni her X_i daęılımıyla alakalı.

İspat devam etmek iin, \bar{X}_n daęılımının beklentisini bulmamız gerekiyor.

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

E dogrusal bir islec (linear operator) olduęu iin disaridan iceri dogru nufuz eder.

$$\begin{aligned} &= \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu \\ &= \mu \end{aligned}$$

Dikkat edelim, bu *ortalamanın* beklentisi, ortalamanın kendisinin hangi degere yaklasacagini hala gostermiyor. Eger oyle olsaydi isimiz bitmis olurdu :) Daha yapacak cok is var.

Simdi \bar{X}_n daęılımının standart sapmasını da bulalım. Diger bir olasilik kuramina gore

$$Y = a + bX$$

$$\text{Var}(Y) = b^2 \text{Var}(X)$$

oldugunu biliyoruz. O zaman,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n} \quad (3)$$

Artık Çebişev kuramını kullanmaya hazırız. İspatlamaya çalıştığımız neydi? $n \rightarrow \infty$ iken,

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Cebisev'den

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2}$$

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$$

$\sigma^2/n\epsilon^2$ 'in sifira gitmesi normal cunku n sonsuza gidiyor.

Peki $P(|\bar{X}_n - \mu| > \epsilon)$ 'nin sifira gittigini gosterdik mi?

$\sigma^2/n\epsilon^2$ 'nin sifira gittigini gosterdik. $\sigma^2/n\epsilon^2$ de $P(|\bar{X}_n - \mu| > \epsilon)$ 'den buyuk olduguna gore, demek ki o da sifira iner.

□

Buyuk Sayilar Kanunu orneklem ortalamasinin ve varyansinin X_i 'in beklentisi ve varyansi ile baglanti kurar. Merkezi Limit Teorisi bir adim daha atar, ve der ki " \bar{X} 'in dagilimi Gaussian dagilim olmalidir yani normal egrisi seklinde cikmalidir!". Teorinin detaylari bu bolumde bulunabilir.

Çebişev Eşitsizliği

Olasılık matematiğinde, büyük sayılar kuramı adında anılan ve olasılık matematiğinin belkemiğini oluşturan kuramı ispatlamak için, diğer bir kuram olan Çebişev eşitsizliğini de anlamamız gerekiyor. Çebişev eşitsizliği bir rasgele değişken, onun ortalaması (beklentisi) ve herhangi bir sabit sayı arasındaki üçlü arasında bir 'eşitsizlik' bağlantısı kurar, ve bu bağlantı diğer olasılık işlemlerimizde ispat verisi olarak işimize yarar.

Teori: Herhangi bir t değeri için,

$$P(|X - \mu| > t) \leq \frac{\sigma^2}{t^2}$$

İspata başlayalım. Entegral ile olasılık hesabı yapmak için bize bir x uzayı lazım.

$$\mathbb{R} = x : |x - \mu| > t$$

Yani \mathbb{R} uzayı, x ile ortalamasının farkının, t 'den büyük olduğu bütün sayıların kümesidir.

O zaman,

$$P(|X - \mu| > t) = \int_{\mathbb{R}} f(x) dx$$

Dikkat edelim $P(\cdot)$ içindeki formül, küme tanımı ile aynı. O yüzden $P(\cdot)$ hesabı ortada daha olmayan, ama varolduğu kesin bir dağılım fonksiyonu tanımlamış da oluyor. Buna $f(x)$ deriz. $P(\cdot)$ 'in, $f(x)$ fonksiyonunun \mathbb{R} üzerinden integral olduğunu olasılığa giriş dersinden bilmemiz lazım.

Eğer $x \in \mathbb{R}$ dersek o zaman

$$\frac{|x - \mu|^2}{t^2} \geq 1$$

t 'nin denkleme bu şekilde nereden geldiği şaşkınlık yaratabilir. Daha önce tanımlanan şu ibareye dikkat edelim, $x : |x - \mu| > t$ diye belirtmiştik. Bu ifadeyi değiştirerek, yukarıdaki denkleme gelebiliriz.

Devam edersek, elimizdeki 1'den büyük bir değer var. Bu değeri kullanarak, aşağıdaki tanımı yapmamız doğru olacaktır.

$$\int_{\mathbb{R}} f(x) dx \leq \int_{\mathbb{R}} \frac{(x - \mu)^2}{t^2} f(x) dx \leq \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

Ortadaki integral niye birinci integralden büyük? Çünkü ortadaki integraldeki $f(x)dx$ ibaresinden önce gelen kısmın, her zaman 1'den büyük olacağını belirttiğimize göre, ikinci integralin birinciden büyük olması normaldir, çünkü birinci integral $f(x)$ olasılık dağılımına bağlı, integral ise bir alan hesabıdır ve olasılık dağılımlarının sonsuzlar arasındaki integrali her zaman 1 çıkar, kaldı ki üstteki x 'in uzayını daha da daralttık.

Evet...Üçüncü integral ispata oldukça yaklaştı aslında. Standart sapma işaretini hala ortada göremiyoruz, fakat son integraldeki ibare standart sapma değerini zaten içeriyor. Önce daha önceki olasılık matematiği bilgimize dayanarak, standart sapmanın tanımını yazıyoruz. Dikkat edelim, bu ibare şu anki ispatımız dahilinden değil, haricinden önceki bilgimize dayanarak geldi. Standart sapmanın tanımı şöyledir.

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

O zaman

$$\frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

yani

$$\int_{\mathbb{R}} f(x) dx \leq \frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

ki $\int_{\mathbb{R}} f(x) dx$ zaten $P(|X - \mu| > t)$ olarak tanımlanmıstı.

□

Merkezi Limit Teorisi (Central Limit Theorem -CLT-)

Buyuk Sayilar Kanunu orneklem ortalamasinin gercek nufus beklentisine yaklasacagini ispatladi. Orneklem herhangi bir dagilimdan gelebiliyordu. CLT bu teoriyi bir adim ilerletiyor ve diyor ki kendisi de bir rasgele degisken olan orneklem ortalamasi \bar{X} Normal dagilima sahiptir! Daha detaylandirmal gerekirse,

Diyelim ki X_1, \dots, X_n orneklemi birbirinden bagimsiz, ayni dagilimli ve ortalamasi μ , standart sapmasi σ olan (ki o da ayni dagilima sahip) bir nufustan geliyorlar. Orneklem ortalamasi \bar{X} , ki bu rasgele degiskenin beklentisinin μ , ve (3)'e gore standart sapmasinin σ/\sqrt{n} oldugunu biliyoruz. Dikkat: \bar{X} 'in kendisinden degil, *beklentisinden* bahsediyoruz, BSK'deki ayni durum, yani ortalama dagiliminin ortalamasi. Teori der ki n buyudukce \bar{X} dagilimi (bu sefer kendisi) bir $N(\mu, \sigma/\sqrt{n})$ dagilimina yaklasir.

Bu ifade genelde standart normal olarak gostrilir, herhangi bir normal dagilimi standart normal'e donusturmeyi daha once gormustuk zaten, beklentiyi cikartip standart sapmaya boluyoruz, o zaman orneklem dagilimi \bar{X} ,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

dagilimina yaklasir diyoruz, ki $Z = N(0, 1)$ dagilimidir, beklentisi sifir, standart sapmasi 1 degerindedir.

Bu teoremin ispatini simdilik vermeyecegiz.

Kaynaklar

[1] <http://mathworld.wolfram.com/MaximumLikelihood.html>

[2] Introduction to Probability and Statistics Using R