

Ozet Istatistikleri, Grafikleri

Beklenti (Expectation)

Bu deger, dagilim $f(x)$ 'in tek sayilik bir ozetidir. Yani beklenti hesabina bir taraftan bir dagilim fonksiyonu girer, diger taraftan tek bir sayi disari cikar.

Tanim

Surekli dagilim fonksiyonlari icin $E(X)$

$$E(X) = \int xf(x)dx$$

ayriksal dagilimlar icin

$$E(X) = \sum_x xf(x)$$

Hesabin, her x degerini onun olasiligi ile carpip topladigina dikkat. Bu tur bir hesap dogal olarak tum x 'lerin ortalamasini verecektir, ve dolayli olarak dagilimin ortalamasini hesaplayacaktır. Ortalama μ_x olarak ta gosterilebilir.

$E(X)$ 'in bir tanim olduguna dikkat, yani bu ifade tamamen bizim yarattigimiz, ortaya cikarttigimiz bir sey, matematigin baz kurallarindan gelerek turetilen bir kavram degil.

Notasyonel basitlik icin ustteki toplam / entegral yerine

$$= \int x dF(x)$$

diyecegiz, bu notasyonel bir kullanim sadece, unutmayalim, reel analizde $\int x dF(x)$ 'in ozel bir anlami var (hoca tam diferansiyel dF 'den bahsediyor).

Beklentinin taniminin kapsamli / eksiksiz olmasi icin $E(X)$ 'in "mevcudiyeti" icin de bir sart tanımlamak gerekir, bu sart soyle olsun,

$$\int_x |x|dF_X(x) < \infty$$

ise beklenti mevcut demektir. Tersi sozkonusu ise beklenti mevcut degildir.

Ornek

$X \sim \text{Unif}(-1, 3)$ olsun. $E(X) = \int x dF(x) = \int xf_X(x)dx = \frac{1}{4} \int_{-1}^3 xdx = 1$.

Ornek

Cauchy dagiliminin $f_X(x) = \{\pi(1+x^2)\}^{-1}$ oldugunu soylemistik. Simdi beklentiyi hesaplayalim. Parcali entegral teknigi lazim, $u = x$, $dv = 1/(1+x^2)$ deriz, ve o zaman $v = \tan^{-1}(x)$ olur, bkz *Ters Trigonometrik Formuller* yazimiz. Demek ki

$$\int |x|dF(x) = \frac{2}{\pi} \int_0^{\infty} \frac{x dx}{1+x^2}$$

2 nereden cikti? Cunku $|x|$ kullaniyoruz, o zaman sinir degerlerinde sadece sifirin sagina bakip sonucu ikiyle carpma yeterli. Bir sabit oldugu icin π ile beraber disari cikiyor. Simdi

$$\int u dv = uv - \int v du$$

uzerinden

$$= [x \tan^{-1}(x)]_0^{\infty} - \int_0^{\infty} \tan^{-1}(x) dx = \infty$$

Yani ustteki hesap sonsuzluga gider. O zaman ustteki tanimimiza gore Cauchy dagiliminin beklentisi yoktur.

Tanim

x_1, \dots, x_n verilerini iceren orneklemen (sample) ortalamasi

$$\bar{x} = \frac{1}{n} \sum x_i \quad (1)$$

Dikkat bu orneklemdeki verinin ortalamasi. Hicbir dagilim hakkında hicbir faraziye yapmadik. Ayrica tanim kullandik, yani bu ifadenin ne oldugu tamamen bize bagli.

Orneklem ortalamasi sadece tek merkezi bir tepesi olan (unimodal) dagilimlar icin gecerlidir. Eger bu temel varsayim gecerli degilse, ortalama kullanarak yapilan hesaplar bizi yanlis yollara goturur. Ayrica bir dagilimi simetrik olup olmadigi da ortalama ya da medyan kullanilip kullanilmamasi kararinda onemlidir. Eger simetrik, tek tepeli bir dagilim var ise, ortalama ve medyan birbirine yakin olacaktir. Fakat veri baska turde bir dagilim ise, o zaman bu iki olcut birbirinden cok farkli olabilir.

Tanim

Y rasgele degiskeninin varyansi (variance)

$$\text{Var}(Y) = E((Y - E(Y))^2)$$

Ifadede toplama ve bolme gibi islemler olmadigina dikkat; onun yerine kare ifadeleri uzerinde beklenti ifadesi var. Yani Y 'nin beklentisini rasgele degiskenin kendisinden cikartip kareyi aliyoruz, ve bu islemin Y 'den gelen tum zar atislari uzerinden beklentisi bize varyansi veriyor. Bir rasgele degisken gorunce onun yerine "dagilimdan uretilen sayi" dusunmek faydalidir, ki bu gercek dunya sart-larindan (ve buyuk miktarda olunca) veri noktalarini temsil eder.

Varyans formulunu acarsak, ileride isimize yarayacak baska bir formül elde ede-biliriz,

$$\text{Var}(Y) = E(Y^2 - 2YE(Y) + (E(Y)^2))$$

$$= E(Y^2) - 2E(Y)E(Y) + (E(Y)^2)$$

$$\text{Var}(Y) = E(Y^2) - (E(Y)^2)$$

Tanim

y_1, \dots, y_n orneklemnin varyansi (literaturde S^2 olarak gecebiliyor,

$$S^2 = \frac{1}{n} \sum (y_i - \bar{y})^2 \quad (2)$$

Standart sapma veri noktalarin "ortalamadan farkinin ortalamasini" verir. Tabii bazen noktalar ortalamamin altinda, bazen ustunde olacaktir, bizi bu negatiflik, pozitiflik ilgilendirmez, biz sadece farkla alakaliyiz. O yuzden her sapmanin karesini aliriz, bunlari toplayip nokta sayisina boleriz.

Ilginc bir cebirsel islem sudur ve bize verinin uzerinden tek bir kez gecerek (one pass) hem sayisal ortalamayi hem de sayisal varyansi hesaplamamizi saglar. Eger \bar{y} tanimini ustteki formule sokarsak,

$$\begin{aligned} &= \frac{1}{n} \sum_i y_i^2 + \frac{1}{n} \sum_i m^2 - \frac{2}{n} \sum_i y_i \bar{y} \\ &= \frac{1}{n} \sum_i y_i^2 + \frac{\bar{y}^2 n}{n} - \frac{2\bar{y}n}{n} \bar{y} \\ &= \frac{1}{n} \sum_i y_i^2 + \bar{y}^2 - 2\bar{y}^2 \\ &= \frac{1}{n} \sum_i y_i^2 - \bar{y}^2 \end{aligned}$$

Bu arada standard sapma varyansin karekokudur, ve biz karekok olan versiyon ile calismayi tercih ediyoruz. Niye? Cunku o zaman veri noktalarinin ve yay- ilma olcusunun birimleri birbiri ile ayni olacak. Eger veri setimiz bir alisveris sepetindeki malzemelerin lira cinsinden degerleri olsaydi, varyans bize sonucu "kare lira" olarak verecekti ve bunun pek anlami olmayacakti.

Medyan ve Yuzdelikler (Percentile)

Ustteki hesaplarin cogu sayilari toplayip, bolmek uzerinden yapildi. Medyan ve diger yuzdeliklerin hesabi (ki medyan 50. yuzdelige tekabul eder) icin eldeki tum degerleri "siraya dizmemiz" ve sonra 50. yuzdelik icin ortadakine bakmamiz gerekiyor. Mesela eger ilk 5. yuzdeligi ariyorsak ve elimizde 80 tane deger var ise, bastan 4. sayiya / vektor hucresine / ogeye bakmamiz gerekiyor. Eger 100 eleman var ise, 5. sayiya bakmamiz gerekiyor, vs.

Bu siraya dizme islemi kritik. Kiyasla ortalama hesabi hangi sirada olursa olsun, sayilari birbirine topluyor ve sonra boluyor. Zaten ortalama ve sapmanin istatistikte daha cok kullanilmasinin tarihi sebebi de aslinda bu; bilgisayar on- cesi cagda sayilari siralamak (sorting) zor bir isti. Bu sebeple hangi sirada olursa olsun, toplayip, bolerek hesaplanabilecek ozetler daha makbuldu. Fakat artik sir- alama islemi kolay, ve veri setleri her zaman tek tepeli, simetrik olmayabiliyor. Ornek veri seti olarak unlu `dellstore2` tabanindaki satis miktarlari kullanirsak,

```
print np.mean(data)
213.948899167

print np.median(data)
214.06

print np.std(data)
125.118481954

print np.mean(data)+2*np.std(data)
464.185863074

print np.percentile(data, 95)
410.4115
```

Goruldugu gibi uc nokta hesabi icin ortalamadan iki sapma otesini kullanirsak, 464.18, fakat 95. yuzdeligi kullanirsak 410.41 elde ediyoruz. Niye? Sebep ortala- manin kendisi hesaplanirken cok uc degerlerin toplama dahil edilmis olmasi ve bu durum, ortalamannin kendisini daha buyuk seviyeye dogru itiyor. Yuzdelik hesabi ise sadece sayilari siralayip belli bazi elemanlari otomatik olarak uc nokta olarak addediyor.

Box Whisker Grafikleri


Tek boyutlu bir verinin dagilimini gormek icin Box ve Whisker grafikleri faydali araclardir; medyan (median), dagilimin genisligini ve siradisi noktaları (outliers) acik sekilde gosterirler. Isim nereden geliyor? Box yani kutu, dagilimin agirlik-
inin nerede oldugunu gosterir, medyanin sagindada ve solunda olmak uzere iki
ceyregin arasindaki kisimdir, kutu olarak resmedilir. Whiskers kedilerin biyik-
larına verilen isimdir, zaten grafikte birazcik biyik gibi duruyorlar. Bu uzantilar
medyan noktasindan her iki yana kutunun iki kati kadar uzatilir sonra verideki
"ondan az olan en buyuk" noktaya kadar geri cekilir. Tum bunlarin disinda kalan
veri ise teker teker nokta olarak grafikte basilir. Bunlar siradisi (outlier) olduklari
icin daha az olacaklari tahmin edilir.

BW grafikleri iki veriyi dagilimsal olarak karsilastirmak icin birebirdir. Mesela
Larsen and Marx adli arastirmacilar cok az veri iceren Quintus Curtius Snodgrass
veri setinin degisik oldugunu ispatlamak icin bir suru hesap yapmislardir, bir
suru matematiksel isleme girmislerdir, fakat basit bir BW grafigi iki setin farklilik-
ini hemen gosterir.

BW grafikleri iki veriyi dagilimsal olarak karsilastirmak icin birebirdir. Mesela
Larsen and Marx adli arastirmacilar cok az veri iceren Quintus Curtius Snodgrass
veri setinin degisik oldugunu ispatlamak icin bir suru hesap yapmislardir, bir
suru matematiksel isleme girmislerdir, fakat basit bir BW grafigi iki setin farklilik-
ini hemen gosterir.

Python üzerinde basit bir BW grafigi

```
spread= rand(50) * 100  
center = ones(25) * 50  
flier_high = rand(10) * 100 + 100  
flier_low = rand(10) * -100  
data =concatenate((spread, center, flier_high, flier_low), 0)  
plt.boxplot(data)  
plt.savefig('05_03.png')
```



Bir diger ornek Glass veri seti üzerinde

```
data = loadtxt("glass.data", delimiter=",")  
head = data[data[:,10]==7]
```

```

tableware = data[data[:,10]==6]
containers = data[data[:,10]==5]

print head[:,1]


data =(containers[:,1], tableware[:,1], head[:,1])

plt.yticks([1, 2, 3], ['containers', 'tableware', 'head'])

plt.boxplot(data,0,'rs',0,0.75)
plt.savefig('05_04.png')

[ 1.51131  1.51838  1.52315  1.52247  1.52365  1.51613  1.51602  1.51623
 1.51719  1.51683  1.51545  1.51556  1.51727  1.51531  1.51609  1.51508
 1.51653  1.51514  1.51658  1.51617  1.51732  1.51645  1.51831  1.5164
 1.51623  1.51685  1.52065  1.51651  1.51711]

```



Parametre Tahmin Ediciler (Estimators)

Maksimum Olurluk (maximum likelihood) kavramini kullanarak ilginç bazı sonuçlara erismek mumkun; bu sayede dagilim fonksiyonlari ve veri arasinda bazi sonuclar elde edebiliriz. Maksimum olurluk nedir? MO ile verinin her noktasi teker teker olasilik fonksiyonuna gecilir, ve elde edilen olasilik sonuclari birbiri ile carpilir. Cogunlukla formül icinde bilinmeyen bir(kac) parametre vardir, ve bu carpim sonrasi, icinde bu parametre(ler) olan yeni bir formül ortaya cikar. Bu nihai formülün kısmi türevi alinip sifira esitlenince cebirsel bazı teknikler ile bilinmeyen parametre bulunabilir. Bu sonuc eldeki veri baglaminda en mumkun (olur) parametre degeridir. Oyle ya, mesela Gaussian $N(10,2)$ dagilimi var ise, 60,90 gibi degerlerin “olurlugu” dusuktur. Gaussin uzerinde ornek,

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}, x \in \mathbb{R}$$

Carpim sonrasi

$$f(x_1, \dots, x_n; \mu, \sigma) = \prod \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x_i - \mu)^2 \right\}$$

$$= \frac{(2\pi)^{-n/2}}{\sigma^n} \exp \left\{ -\frac{\sum (x_i - \mu)^2}{2\sigma^2} \right\}$$

Ustel kisim $-n/2$ nereden geldi? Cunku bolen olan karekoku uste cikardik, boylece $-1/2$ oldu, n cunku n tane veri noktası yuzunden formül n kere carpiliyor. Veri noktaları x_i icinde. Eger log, yani \ln alirsak \exp 'den kurtuluruz, ve biliyoruz ki log olurlugu maksimize etmek normal olurlugu maksimize etmek ile ayni seydir, cunku \ln transformasyonu monoton bir transformasyondur. Ayrica olurluk icbukeydir (concave) yani kesin tek bir maksimumu vardır.

$$\ln f = -\frac{1}{2}n \ln(2\pi) - n \ln \sigma - \frac{\sum (x_i - \mu)^2}{2\sigma^2}$$

Turevi alip sifira esitleyelim

$$\frac{\partial(\ln f)}{\partial \mu} = \frac{\sum (x_i - \mu)^2}{2\sigma^2} = 0$$

$$\hat{\mu} = \frac{\sum x_i}{n}$$

Bu sonuc (1)'deki formül, yani örneklem ortalaması ile ayni! Fakat buradan hemen bir bağlantıya zıplamadan önce sunu hatırlayalım - örneklem ortalaması formülünü *biz* tanımladık. “Tanım” diyerek bir ifade yazdık, ve budur dedik. Simdi sonradan, verinin dağılımının Gaussian olduğunu farzederek, bu verinin mümkün kılabilceği en optimal parametre değeri nedir diye hesap ederek ayni formüle eristik, fakat bu bir anlamda bir güzel raslantı oldu.. Daha doğrusu bu aynilik Gaussian / Normal dağılımlarının “normalligi” ile alakalı muhakkak, fakat örnekleme ortalaması hiçbir dağılım faraziyesi yapmıyor, herhangi bir dağılımdan geldiği bilinen ya da bilinmeyen bir veri üzerinde kullanılabilir. Bunu unutmayalım. İstatistikte matematiğin lakaytlasması (sloppy) kolaydır, o sebeple neyin tanım, neyin hangi faraziyeyle göre optimal, neyin nüfus (population) neyin örneklem (sample) olduğunu hep hatırlamamız lazım.

Devam edelim, maksimum olurluk ile $\hat{\sigma}$ hesaplayalım,

$$\frac{\partial(\ln f)}{\partial \sigma} = -\frac{n}{\sigma} + \frac{\sum (x_i - \mu)^2}{2\sigma^3} = 0$$

Cebirsel birkaç düzenleme sonrası ve μ yerine yeni hesapladığımız $\hat{\mu}$ kullanarak,

$$\hat{\sigma}^2 = \frac{\sum (x_i - \hat{\mu})^2}{n}$$

Bu da örneklem varyansı ile ayni!

Yansizlik (Unbiasedness)

Tahmin edicilerin kendileri de birer rasgele degisken oldugu icin her orneklem icin degisik degerler verirler. Diyelim ki θ icin bir tahmin edici $\hat{\theta}$ hesapliyoruz, bu $\hat{\theta}$ gercek θ icin bazi orneklemler icin cok kucuk, bazi orneklemler icin cok buyuk sonuclar (tahminler) verebilecektir. Kabaca ideal durumun, az cikan tahminlerin cok cikan tahminleri bir sekilde dengelemesi oldugunu tahmin edebiliriz, yani tahmin edicinin uretecegi pek cok degerin θ 'yi bir sekilde "ortalamasi" iyi olacaktir.



Bu durumu soyle aciklayalim, madem tahmin ediciler birer rasgele degisken, o zaman bir dagilim fonksiyonlari var. Ve ustteki resimde ornek olarak $\hat{\theta}_1, \hat{\theta}_2$ olarak iki tahmin edici gosteriliyor mesela ve onlara tekabul eden yogunluklar $f_{\hat{\theta}_1}, f_{\hat{\theta}_2}$. Ideal durum soldaki resimdir, yogunlugun fazla oldugu yer gercek θ 'ya yakin olmasi. Bu durumu matematiksel olarak nasil belirtiriz? Beklenti ile!

Tanim

Y_1, \dots, Y_n üzerindeki θ tahmin edicisi $\hat{\theta}$ 'den alınmis rasgele orneklem. Eger tum θ 'lar icin $E(\hat{\theta}) = \theta$ ise, bu durumda tahmin edicinin yansiz oldugu soylenebilir.

Ornek olarak maksimum olurluk ile onceden hesapladigimiz $\hat{\theta}$ tahmin edicisine bakalim. Bu ifade

$$\hat{\sigma}^2 = \frac{1}{n} \sum (Y_i - \hat{\mu})^2$$

ya da

$$\hat{\sigma}^2 = \frac{1}{n} \sum_i (Y_i - \bar{Y})^2$$

ile belirtildi. Tahmin edici $\hat{\sigma}^2, \sigma^2$ icin yansiz midir? Tanimimize gore eger tahmin edici yansiz ise $E(\hat{\sigma}^2) = \sigma^2$ olmalidir.

Not: Faydali olacak bazi esitlikler, daha onceden gordugumuz

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

ve sayisal ortalama \bar{Y} 'nin beklentisi $E(\bar{Y}) = E(Y_i)$, ve $\text{Var}(\bar{Y}) = 1/n \text{Var}(Y_i)$.

Baslayalım,

$$E(\hat{\sigma}^2) = E\left(\frac{1}{n} \sum_i (Y_i - \bar{Y})^2\right)$$

Parantez icindeki $1/n$ sonrasindaki ifadeyi acarsak,

$$\begin{aligned} \sum_i (Y_i - \bar{Y})^2 &= \sum_i (Y_i^2 - 2Y_i\bar{Y} + \bar{Y}^2) \\ &= \sum_i Y_i^2 - 2 \sum_i Y_i\bar{Y} + n\bar{Y}^2 \end{aligned}$$

$\sum_i Y_i$ 'nin hemen yaninda \bar{Y} goruyoruz. Fakat \bar{Y} 'nin kendisi zaten $1/n \sum_i Y_i$ demek degil midir? Ya da, toplam icinde her i icin degismeyecek \bar{Y} 'yi toplam disina ceekersek, $\bar{Y} \sum_i Y_i$ olur, bu da $\bar{Y} \cdot n\bar{Y}$ demektir ya da $n\bar{Y}^2$,

$$\begin{aligned} &= \sum_i Y_i^2 - 2n\bar{Y}^2 + n\bar{Y}^2 \\ &= \sum_i Y_i^2 - n\bar{Y}^2 \end{aligned}$$

Dikkat, artik $-n\bar{Y}^2$ toplama isleminin *disinda*. Simdi beklentiye geri donelim,

$$= E\left(\frac{1}{n} \left(\sum_i Y_i^2 - n\bar{Y}^2 \right)\right)$$

$1/n$ disari cekilir, beklenti toplamdan iceri nufuz eder,

$$= \frac{1}{n} \left(\sum_i E(Y_i^2) - nE(\bar{Y}^2) \right)$$

Daha once demistik ki (genel baglamda)

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

Bu ornek icin harfleri degistirirsek,

$$\text{Var}(Y_i) = E(Y_i^2) - E(Y_i)^2$$

Yani

$$E(Y_i^2) = \text{Var}(Y_i) + E(Y_i)^2$$

$E(Y_i) = \mu$ olduğunu biliyoruz,

$$E(Y_i^2) = \text{Var}(Y_i) + \mu^2$$

Aynısını $E(\bar{Y}^2)$ için kullanırsak,

$$E(\bar{Y}^2) = \text{Var}(\bar{Y}) + E(\bar{Y})^2$$

$E(\bar{Y}) = \mu$,

$$E(\bar{Y}^2) = \text{Var}(\bar{Y}) + \mu^2$$

$$= \frac{1}{n} \left(\sum_i \text{Var}(Y_i) + \mu^2 - n(\text{Var}(\bar{Y}) + \mu^2) \right)$$

$\text{Var}(Y_i) = \sigma^2$, ve başta verdiğimiz eşitlikler ile beraber

$$= \frac{1}{n} \left(\sum_i (\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right)$$

Tekrar hatırlatalım, \sum_i sadece ilk iki terim için geçerli, o zaman, ve sabit değerleri n kadar topladığımıza göre bu aslında bir çarpım işlemi olur,

$$= \frac{1}{n} \left(n\sigma^2 + n\mu^2 - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right)$$

$$= \sigma^2 + \mu^2 - \frac{\sigma^2}{n} - \mu^2$$

$$= \sigma^2 - \frac{\sigma^2}{n}$$

$$= \frac{n\sigma^2}{n} - \frac{\sigma^2}{n}$$

$$= \frac{n\sigma^2 - \sigma^2}{n}$$

$$= \frac{\sigma^2(n-1)}{n}$$

$$= \sigma^2 \frac{n-1}{n}$$

Goruldugu gibi eristigimiz sonuc σ^2 degil, demek ki bu tahmin edici yansiz degil. Kontrol tamamlandi.

Fakat eristigimiz son denklem bize baska bir sey gosteriyor, eger ustteki sonucu $\frac{n}{n-1}$ ile carpsaydik, σ^2 elde etmez miydik? O zaman yanli tahmin ediciyi yansiz hale cevirmek icin, onu $\frac{n}{n-1}$ ile carpariz ve

$$\begin{aligned} & \frac{n}{n-1} \frac{1}{n} \sum_i (Y_i - \bar{Y})^2 \\ &= \frac{1}{n-1} \sum_i (Y_i - \bar{Y})^2 \end{aligned}$$

Ustteki ifade σ^2 'nin yansiz tahmin edicisidir.

Hesap icin kullandiginiz kutuphanelerin yanli mi yansiz mi hesap yaptigini bilmek iyi olur, mesela Numpy versiyon 1.7.1 itibariyle yanli standart sapma hesabi yapıyor, fakat Pandas yansiz olani kullanıyor (Pandas versiyonu daha iyi)

```
import pandas as pd
arr = np.array([1,2,3])
print 'numpy', np.std(arr)
print 'pandas', float(pd.DataFrame(arr).std())

numpy 0.816496580928
pandas 1.0
```

Büyük Sayılar Kanunu (Law of Large Numbers)

Olasılık kuramında önemli matematiksel bir denklem, büyük sayılar kanunudur. Bu kanun, örneklem (sample) ile rasgele degiskenler, yani matematiksel olasilik dagilimleri olan dünya arasinda bir baglanti gorevi gorur.

Kanun kabaca bildigimiz günlük bir gercegin matematiksel ispatıdır da denebilir. Yazı-tura atarken yazı çıkma ihtimalinin 1/2 olduğunu biliyoruz (cunku zar atisini bir dagilim gibi goruyoruz). Herhalde çoğumuz da bu yazı-tura işleminin "bir çok kere" tekrarlandığı durumda, toplam sonucun aşağı yukarı yarısının yazı olacağını tahmin biliyoruz.

Matematiksel olarak, farzedelim ki her yazı-tura atışı bir deney olsun. Her ayrı deneyin sonucu $X_1, X_2 \dots X_n$ olarak rasgelen değişkenlerle tanımlanmış olsun, bu degiskenlerin dagilimi ayni (cunku ayni zar), ama birbirlerinden bagimsizlar (cunku

her deney digerinden alakasiz). Değişkenlerin sonucu 1 ya da 0 değeri taşıyacak, Yazı=1, Tura=0.

Buyuk Sayılar Kanunu tum bu deney sonuclarinin, yani rasgele degiskenlerin av-eraji alinirsa, yani $\bar{X} = X_1 + \dots + X_n$ ile, elde edilen sonucun X_i 'lerin (ayni olan) beklentisine yaklasacaginin soyler, yani n büyüdükçe \bar{X}_n 'in $1/2$ 'ye yaklaştığını ispatlar, yani $E[X_i] = 1/2$ degerine. Notasyonel olarak $E(X_i) = \mu$ olarak da gosterilebilir.

Formulsel olarak, herhangi bir $\epsilon > 0$ icin,

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| \leq \epsilon) = 1$$

ya da

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \epsilon) = 0$$

ya da

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Burada ne soylendigine dikkat edelim, X_i dagilimi *ne olursa olsun*, yani ister Binom, ister Gaussian olsun, *orneklem* uzerinden hesaplanan sayisal ortalamanin (empirical mean) formulsel olasilik beklentisine yaklastigini soyluyoruz! X_i 'ler en absurt dagilimlar olabilirler, bu dagilimlari fonksiyonu son derece cetrefil, tek tepeli (unimodal) bile olmayabilir, o formuller uzerinden beklenti icin gereken integralin belki analitik cozumu bile mevcut olmayabilir! Ama yine de ortalama, o dagilimlari beklentisine yaklasacaktır. Istatistik ile olasilik teorisi arasindaki cok onemli bir baglanti bu.

Sonuc sasirtici, fakat bir ek daha yapalim, sezgisel (intuite) olarak bakarsak aslinda sonuc cok sasirtici olmayabilir. Niye? Diyelim ki genel veri $N(\mu, \sigma^2)$ seklinde bir Normal dagilimdan geliyor ve orneklem de bu sebeple ayni dagilima sahip. Bu durumda orneklemdeki veri noktalarinin μ 'ya yakin degerler olmasini beklemek mantikli olmaz mi? Cunku bu dagilim "zar atinca" ya da bir genel nufustan bir "ornek toplayinca" (ki bunu bir anlamda istatistiksel bir zar atisi olarak gorebiliriz) onu μ, σ^2 'e gore atacak. Ornekleme zar atisi sonuclari olarak gordugumuze gore elde edilen verilerin bu sekilde olacagi sasirtici olmamali. Ve bu zar atislarinin ortalamasinin, son derece basit bir aritmetik bir islemlerle hesaplaniyor olsa bile, μ 'ye yaklasmasi normal olmalidir.

Bu arada, bu argumana tersten bakarsak Monte Carlo integralinin niye isledigine gorebiliriz (bkz *Monte Carlo, Entegraller, MCMC* yazisi).

Ozellikle orneklem ile genel nufus (population) arasinda kurulan baglantiya dikkat edelim. Istatigin onemli bir bolumunun bu baglanti oldugu soylenebilir. Her orneklem, bilmedigimiz ama genel nufusu temsil eden bir dagilimla ayni dagilima sahip olan X_i 'dir dedik, ve bu aynilikten ve bagimsizlikten yola cikarak

bize genel nufus hakkında bir ipucu saglayan bir kanun gelistirdik (ve birazdan ispatlayacagiz).

Ispata baslayalim.

X_1, X_2, \dots, X_n bagimsiz degiskenler olsun.

$$E(X_i) = \mu$$

$$\text{Var}(X_i) = \sigma$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

\bar{X}_n de bir rasgele deęiřkendir, unku \bar{X}_n deęiřkeni her X_i daęılımıyla alakali.

İspat devam etmek iin, \bar{X}_n daęılımının beklentisini bulmamız gerekiyor.

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

E dogrusal bir islec (linear operator) oldugu icin disaridan iceri dogru nufuz eder.

$$\begin{aligned} &= \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu \\ &= \mu \end{aligned}$$

Dikkat edelim, bu *ortalamanin* beklentisi, ortalamanin kendisinin hangi degere yaklasacagini hala gostermiyor. Eger oyle olsaydi isimiz bitmis olurdu :) Daha yapacak cok is var.

Simdi \bar{X}_n daęılımının standart sapmasını da bulalım. Diger bir olasilik kuramina gore

$$Y = a + bX$$

$$\text{Var}(Y) = b^2 \text{Var}(X)$$

oldugunu biliyoruz. O zaman,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} n \sigma^2 = \frac{\sigma^2}{n}$$

Artık Çebişev kuramını kullanmaya hazırız. İspatlamaya çalıştığımız neydi? $n \rightarrow \infty$ iken,

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Çebisev'den

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2}$$

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$$

$\sigma^2/n\epsilon^2$ 'in sifira gitmesi normal cunku n sonsuza gidiyor.

Peki $P(|\bar{X}_n - \mu| > \epsilon)$ 'nin sifira gittigini gosterdik mi?

$\sigma^2/n\epsilon^2$ 'nin sifira gittigini gosterdik. $\sigma^2/n\epsilon^2$ de $P(|\bar{X}_n - \mu| > \epsilon)$ 'den buyuk olduguna gore, demek ki o da sifira iner.

□

Buyuk Sayilar Kanunu orneklem ortalamasinin ve varyansinin X_i 'in beklentisi ve varyansi ile baglanti kurar. Merkezi Limit Teorisi bir adim daha atar, ve der ki " \bar{X} 'in dagilimi Gaussian dagilim olmalidir yani normal egrisi seklinde cikmalidir!". Teorinin detaylari bu bolumde bulunabilir.

Çebişev Eşitsizliği

Olasılık matematiğinde, büyük sayılar kuramı adında anılan ve olasılık matematiğinin belkemiğini oluşturan kuramı ispatlamak için, diğer bir kuram olan Çebişev eşitsizliğini de anlamamız gerekiyor. Çebişev eşitsizliği bir rasgele değişken, onun ortalaması (beklentisi) ve herhangi bir sabit sayı arasındaki üçlü arasında bir 'eşitsizlik' bağlantısı kurar, ve bu bağlantı diğer olasılık işlemlerimizde ispat verisi olarak işimize yarar.

Teori: Herhangi bir t değeri için,

$$P(|X - \mu| > t) \leq \frac{\sigma^2}{t^2}$$

İspata başlayalım. Entegral ile olasılık hesabı yapmak için bize bir x uzayı lazım.

$$\mathbb{R} = x : |x - \mu| > t$$

Yani \mathbb{R} uzayı, x ile ortalamasının farkının, t 'den büyük olduğu bütün sayıların kümesidir.

O zaman,

$$P(|X - \mu| > t) = \int_{\mathbb{R}} f(x) dx$$

Dikkat edelim $P(\cdot)$ içindeki formül, küme tanımı ile aynı. O yüzden $P(\cdot)$ hesabı ortada daha olmayan, ama varolduğu kesin bir dağılım fonksiyonu tanımlamış da oluyor. Buna $f(x)$ deriz. $P(\cdot)$ 'in, $f(x)$ fonksiyonunun \mathbb{R} üzerinden entegral olduğunu olasılığa giriş dersinden bilmemiz lazım.

Eğer $x \in \mathbb{R}$ dersek o zaman

$$\frac{|x - \mu|^2}{t^2} \geq 1$$

t 'nin denkleme bu şekilde nereden geldiği şaşkınlık yaratabilir. Daha önce tanımlanan şu ibareye dikkat edelim, $x : |x - \mu| > t$ diye belirtmiştik. Bu ifadeyi değiştirerek, yukarıdaki denkleme gelebiliriz.

Devam edersek, elimizdeki 1'den büyük bir değer var. Bu değeri kullanarak, aşağıdaki tanımı yapmamız doğru olacaktır.

$$\int_{\mathbb{R}} f(x) dx \leq \int_{\mathbb{R}} \frac{(x - \mu)^2}{t^2} f(x) dx \leq \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

Ortadaki entegral niye birinci entegralden büyük? Çünkü ortadaki entegraldeki $f(x) dx$ ibaresinden önce gelen kısmın, her zaman 1'den büyük olacağını belirttiğimize göre, ikinci entegralin birinciden büyük olması normaldir, çünkü birinci entegral $f(x)$ olasılık dağılımına bağlı, entegral ise bir alan hesabıdır ve olasılık dağılımlarının sonsuzlar arasındaki entegrali her zaman 1 çıkar, kaldı ki üstteki x 'in uzayını daha da daralttık.

Evet...Üçüncü entegral ispata oldukça yaklaştı aslında. Standart sapma işaretini hala ortada göremiyoruz, fakat son entegraldeki ibare standart sapma değerini zaten içeriyor. Önce daha önceki olasılık matematiği bilgimize dayanarak, standart sapmanın tanımını yazıyoruz. Dikkat edelim, bu ibare şu anki ispatımız

dahilinden değil, haricinden önceki bilgimize dayanarak geldi. Standart sapmanın tanımı şöyledir.

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

O zaman

$$\frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

yani

$$\int_{\mathbb{R}} f(x) dx \leq \frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

ki $\int_{\mathbb{R}} f(x) dx$ zaten $P(|X - \mu| > t)$ olarak tanımlanmıstı.

□

Merkezi Limit Teorisi (Central Limit Theorem -CLT-)

Buyuk Sayılar Kanunu örneklem ortalamasının gercek nufus beklentisine yaklasacagini ispatladi. Orneklem herhangi bir dagilimdan gelebiliyordu. CLT bu teoriyi bir adim ilerletiyor ve diyor ki kendisi de bir rasgele degisken olan orneklem ortalamasi \bar{X} Normal dagilima sahiptir! Daha detaylandirmal gerekirse,

Diyelim ki X_1, \dots, X_i orneklemi birbirinden bagimsiz, ayni dagilimli ve ortalamasi μ , standart sapmasi σ olan (ki o da ayni dagilima sahip) bir nufustan geliyorlar. Orneklem ortalamasi \bar{X} , ki bu rasgele degiskenin beklentisinin μ , ve (3)'e gore standart sapmasinin σ/\sqrt{n} oldugunu biliyoruz. Dikkat: \bar{X} 'in kendisinden degil, *beklentisinden* bahsediyoruz, BSK'deki ayni durum, yani ortalama dagiliminin ortalamasi. Teori der ki n buyudukce \bar{X} dagilimi (bu sefer kendisi) bir $N(\mu, \sigma/\sqrt{n})$ dagilimina yaklasir.

Bu ifade genelde standart normal olarak gostrilir, herhangi bir normal dagilimi standart normal'e donusturmeyi daha once gormustuk zaten, beklentiyi cikartip standart sapmaya boluyoruz, o zaman orneklem dagilimi \bar{X} ,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

dagilimina yaklasir diyoruz, ki $Z = N(0, 1)$ dagilimidir, beklentisi sifir, standart sapmasi 1 degerindedir.

Bu teoremin ispatini simdilik vermeyecegiz.

Kaynaklar

[1] <http://mathworld.wolfram.com/MaximumLikelihood.html>

[2] Introduction to Probability and Statistics Using R